

УДК 004.9

ОЦИФРОВКА ХИМИЧЕСКИХ КНИГ С ИСПОЛЬЗОВАНИЕМ МАШИННОГО ЗРЕНИЯ

Алакшин М. С.^{1,2}, Рыбак А. В.^{1,2}, Ткачѳв Д. А.^{1,2}, Трофимов И. Л.^{2,3}

¹ Федеральное государственное бюджетное образовательное учреждение высшего образования «Иркутский государственный университет»

² Федеральный исследовательский центр «Иркутский институт химии им. А. Е. Фаворского Сибирского отделения Российской академии наук», г. Иркутск

³ Государственная публичная научно-техническая библиотека Сибирского отделения Российской академии наук, г. Новосибирск

Резюме

НАПИСАТЬ резюме

Ключевые слова

НАПИСАТЬ ключевые слова

DIGITIZATION OF CHEMISTRY BOOKS USING MACHINE VISION

Alakshin M. S.^{1,2}, Rybak A. V.^{1,2}, Tkachev D. A.^{1,2}, Trofimov I. L.^{2,3}

¹ Federal State Budgetary Educational Institution of Higher Education "Irkutsk State University"

² Federal Research Center "Irkutsk Institute of Chemistry named after A. E. Favorsky, Siberian Branch of the Russian Academy of Sciences Irkutsk

³ State Public Scientific and Technical Library of the Siberian Branch of the Russian Academy of Sciences, Novosibirsk

Abstract

НАПИСАТЬ резюме

Keywords

НАПИСАТЬ ключевые слова

Введение

Знания, содержащиеся в химических книгах, монографиях и архивных выпусках журналов, сохраняют высокую научную и практическую ценность: в них зафиксированы методики синтеза, экспериментальные наблюдения, справочные сведения о веществах и их свойствах, а также контекст, необходимый для воспроизводимости результатов. При этом существенная часть такого корпуса литературы до сих пор существует в виде физических изданий или в виде сканированных книг, которые удобны для чтения человеком, но плохо приспособлены для автоматизированного анализа и интеграции в современные информационные системы.

На фоне развития информационных технологий и интеллектуального поиска становится актуальной задача извлечения знаний из химических книг с последующей структуризацией и верификацией. Однако на практике оцифровка часто сводится к распознаванию текста и формированию «поискового PDF» [2], что позволяет выполнять лишь поверх-

ностный текстовый поиск. В химической литературе значимая часть информации представлена не в виде текста, а в виде графических объектов: структурных формул, схем реакций. Если эти элементы не переводятся в машинно-обрабатываемые представления, то большая доля смысла документа остается вне цифрового контура и фактически недоступна для алгоритмов поиска, сопоставления и анализа [1].

В данной работе рассматривается подход к комплексной оцифровке химической литературы, ориентированный не только на извлечение текстового слоя, но и на распознавание и структурирование графической химической информации, что позволяет разработать систему интеллектуального поиска по книгам.

Классификация машинного зрения

Машинное зрение (Computer Vision, CV) представляет собой область искусственного интеллекта, изучающую методы автоматического анализа изображений и видео с целью извлечения из них семантически значимой информации [3]. В работе Рублев-




Рис. 1. а) Классификация искусственного интеллекта; б) Классификация компьютерного зрения.
Fig. 1. а) Classification of artificial intelligence; б) Classification of computer vision.

ского [4] машинное зрение выделяется как внешнее кольцо в общей классификации искусственного интеллекта (см. рис. 1 а). Машинное зрение включающий задачи обработки документов, выделения структурных областей страницы и распознавания содержащейся на ней информации. Частным направлением компьютерного зрения является анализ изображений документов (Document Image Analysis или Document Understanding), в рамках которого решаются задачи сегментации страницы, распознавания текста, таблиц, графики и иных содержательных элементов [6, 7].

Одной из наиболее известных задач данного направления является OCR (Optical Character Recognition), ориентированная на извлечение текстовой информации из изображений документов [8]. Однако, как было сказано, в химической литературе значимая часть информации представлена не только текстом, но и графическими структурами: молекулярными формулами, схемами реакций и комбинированными текстово-графическими объектами. Поэтому наряду с OCR требуется использовать специализированные методы OCSR Optical Chemical Structure Recognition, предназначенные для восстановления химических структур по их изображению. С методологической точки зрения OCSR не сводится к обычному OCR, поскольку предполагает восстановление молекулярного графа, а не только линейной последовательности символов. Таким образом, OCR и OCSR целесообразно рассматривать как родственные, но

не вложенные подзадачи анализа изображений химических документов (см. рис. 1 б).

Проблемы с извлечением данных из сканированных книг

Необходимость применения методов компьютерного зрения в рамках данной работы обусловлена тем, что автоматизация обработки документов требует не только распознавания текста, но и предварительного анализа изображения документа. Как показано в работе А. Р. Давлетова [2], современные системы решают задачи предварительной обработки изображения, обнаружения текстовых областей, анализа компоновки страницы и последующего распознавания символов и слов. Такой подход позволяет преобразовывать сканированные документы, PDF-файлы и изображения, полученные при сканировании, в машиночитаемый текст, пригодный для поиска, редактирования и дальнейшего извлечения данных [2].

По сравнению с ручной обработкой автоматизированный подход сокращает время ввода данных, снижает влияние человеческого фактора, уменьшает количество ошибок и упрощает поиск и доступ к информации [2].

Сегментация страницы

Для распознавания документов критично учитывать регулярную структуру страницы и взаимное расположение блоков, поскольку страница научного документа представляет собой не просто непрерыв-

ное изображение текста, а композицию из различных смысловых областей: заголовков, основного текста, подписей к рисункам, таблиц, формул, схем, иллюстраций и служебных элементов [7].

При этом качество сканированной книги также существенно влияет на надежность распознавания: шум, перекося, неравномерная засветка и другие дефекты заметно ухудшают последующие этапы OCR и анализа структуры документа [8].

Эта задача относится к направлению анализа изображений документов и играет роль промежуточного звена между общими методами машинного зрения и прикладными системами OCR. Если этап сегментации пропускается или выполняется неточно, то OCR-система может воспринимать графические объекты как текст, объединять соседние колонки, терять подписи к рисункам, ошибочно включать части формул в текстовый поток или, наоборот, игнорировать важные текстовые фрагменты. Для химической литературы данная проблема особенно существенна, поскольку на одной странице часто одновременно присутствуют обычный текст, структурные химические формулы, схемы реакций, таблицы и обозначения, различающиеся как по визуальной форме, так и по способу дальнейшей обработки.

С практической точки зрения сегментация страницы позволяет перейти от обработки документа как единого изображения к обработке набора специализированных областей. После выделения таких областей (см. рис. 2) к каждой из них может быть применен собственный алгоритм: к текстовым блокам — OCR, к структурным формулам — методы распознавания химической графики, к таблицам — алгоритмы восстановления табличной структуры, к рисункам и схемам — отдельные процедуры анализа изображений. Таким образом, сегментация формирует основу всего конвейера оцифровки: *страница целиком → выделение блоков → специализированное распознавание → структурированное представление знаний*.

Современные подходы к анализу макета документа опираются на методы глубокого обучения, позволяющие автоматически выделять типовые области страницы и учитывать их пространственный контекст. В работе P. Renton, P. Chatto и соавторов представлен инструмент *LayoutParser*, ориентированный на унифицированный анализ структуры документов на основе моделей глубокого обучения, что подтверждает практическую значимость этапа предварительной сегментации для дальнейшего извлечения информации из сложных страниц [6]. Ис-

пользование подобных подходов особенно актуально для оцифровки архивных и сканированных книг, где вариативность верстки, качество печати и наличие графических элементов делают задачу прямого распознавания без предварительного структурного анализа существенно менее надежной.

Предобработка изображения

Большинство архивных химических книг и сканированных материалов характеризуются неоднородным качеством. В работе Akhil [5] выделялись следующие проблемы с изображениями при обработке:

- Низкое разрешение / размытость (рис. 3 а)
- Шум, зернистость, артефакты сжатия (рис. 3 б)
- Неравномерная засветленность / тени (рис. 3 с)
- Ориентация страницы с малым поворотом (рис. 3 д)

Эти факторы напрямую влияют на точность распознавания как и графических формул и реакций так и текста. Поэтому перед обработкой самой OCR необходимо сделать предобработку и нормализацию изображения.

Проблемы с преобразованием химических реакций и молекул в машиночитаемый вид

Химические формулы и схемы реакций существенно сложнее для автоматической обработки, чем обычный текст, поскольку их естественное представление является не линейной последовательностью символов, а графовой структурой. В молекулярном графе вершины соответствуют атомам, а рёбра — химическим связям; реакция, в свою очередь, может рассматриваться как преобразование одного множества молекулярных графов в другое. Поэтому химическая запись несёт смысл не только через набор символов, но и через топологию, тип связей, ароматичность, заряды, стереохимию и пространственные отношения между фрагментами структуры. Именно это отличает задачу распознавания формул от классического OCR: если для текста ключевой является последовательность символов, то для химической формулы необходимо восстановить структуру графа и затем представить её в форме, пригодной для хранения, поиска и последующего анализа [9, 10].

Дополнительную сложность создаёт то, что в химической литературе используются по меньшей мере две распространённые графические нотации записи молекул: подробная (развёрнутая) и скелетная (см. рис. 4). В подробной записи явно показываются




Рис. 2. Схема сегментации

Fig. 2. Segmentation scheme

атомы и значительная часть связей, что облегчает интерпретацию человеком, но увеличивает визуальную насыщенность изображения. В скелетной нотации, напротив, большинство атомов углерода и связанные с ними атомы водорода опускаются, а углеродный каркас кодируется линиями, вершины и концы которых интерпретируются как атомы углерода; гетероатомы, кратные связи, заряды и функциональные группы отображаются явно. Именно скелетная запись наиболее типична для органической химии и научных публикаций, однако она значительно усложняет автоматическое распознавание, так как часть информации в ней задаётся по соглашению, а не прописывается явно. В результате алгоритм должен не просто “увидеть линии”, но восстановить скрытые атомы, валентности и химически допустимую структуру [10].

После распознавания графическое изображение молекулы должно быть переведено в машинно-обрабатываемый формат. В современной хемоинформатике для этого используются несколько основных способов представления структур. К числу наиболее распространённых относятся SMILES (Simplified Molecular Input Line Entry System), InChI (International Chemical Identifier), файловые форматы Molfile и SDF, XML-ориентированный CML (Chemical Markup Language), а для реакций — RXNfile, RDF, а также строковые языки наподобие SMIRKS для описания реакционных преобразований. Эти форматы различаются по назначению: одни удобны для компактной линейной записи и поиска, другие — для хранения полной структурной информации, координат, метаданных и реакционных схем. Обзор таких

представлений и их роли в химической информатике приведён в работах по компьютерному представлению химических структур и форматам химических данных [10, 13, 14].

В данной работе в качестве основного текстового представления структуры выбран формат SMILES, предложенный как компактный язык линейной записи молекул [11, 12]. Его выбор обусловлен несколькими причинами. Во-первых, SMILES является кратким и человекочитаемым: одна молекула кодируется строкой, удобной для хранения в базах данных, индексации, поиска и передачи между программными компонентами. Во-вторых, SMILES широко поддерживается в современных библиотеках и инструментах хемоинформатики, что облегчает интеграцию распознанных структур в конвейер обработки, верификации и поиска. В-третьих, SMILES особенно удобен в задачах, где химическая информация должна быть включена в текстовый или гибридный контур обработки — например, при индексировании документов, построении RAG-систем, текстовом сравнении структур или использовании языковых моделей. В отличие от графического изображения, строка SMILES может быть быстро сопоставлена, нормализована, проверена на корректность и преобразована обратно в молекулярный граф, что делает её практическим компромиссом между компактностью, выразительностью и вычислительной удобностью [10, 11].

При этом важным свойством SMILES является неоднозначность представления (см. рис. 5): одна и та же молекула может быть записана несколькими




Рис. 3. Пример плохого качества сканированных книг а) Размытость; б) Шум; в) Неравномерная засветлённость; д) Ориентация страницы с малым поворотом.

Fig. 3. An example of poor quality scanned books a) Blur; b) Noise; c) Uneven illumination; d) Page orientation with low rotation.




Рис. 4. Пример разных нотаций а) подробная; б) скелетная.

Fig. 4. Example of different notations a) detailed; b) skeletal.




Рис. 5. пример неоднозначного представление форму
 Fig. 5. example of ambiguous form representation

различными, но эквивалентными строками. Это связано с тем, что линейная запись строится на основе обхода графа, а один и тот же граф допускает разные порядки обхода, разные точки старта, разные способы нумерации циклов, а также различные варианты явного или неявного задания некоторых структурных особенностей. Например, одна и та же структура может быть записана через разные эквивалентные последовательности ветвлений или с использованием разных соглашений для ароматических фрагментов. В задачах хранения и поиска это создаёт проблему: если использовать произвольный SMILES, то идентичные молекулы могут быть представлены разными строками, что затрудняет дедупликацию, построение индексов и сопоставление результатов распознавания [12].

Для устранения этой неоднозначности используется канонический SMILES, то есть строковое представление, которое строится по детерминированному алгоритму канонизации и назначает данной структуре единственную «стандартную» форму записи в рамках конкретной программной системы. Идея канонизации состоит в том, чтобы сначала определить уникальный порядок атомов на основе свойств графа, а затем сгенерировать строку по фиксированным правилам обхода. Это позволяет переводить множество эквивалентных SMILES-представлений одной и той же молекулы к одной нормализованной форме. Однако важно учитывать, что канонический SMILES не является абсолютно универсальным мировым стандартом: разные программные пакеты могут использовать разные алгоритмы канонизации, поэтому канонические строки, полученные, например, в двух различных хемоинформатических библиотеках, могут отличаться при сохранении химической эквивалентности. Тем не менее в рамках одного конвейера обработки канонический SMILES является чрезвычайно полезным инструментом, поскольку обеспечивает нормализацию результатов распознавания, устойчивое сравнение структур и корректную интеграцию извлечённых данных в базы знаний и поисковые индексы [12, 14, 15]. Таким образом, выбор SMILES в сочетании с последующей канонизацией представляет собой практически оправданное решение для задач оцифровки и структурирования химической литературы.

Поэтому задача комплексной оцифровки требует:

Поэтому задача комплексной оцифровки требует:

1. сегментации страницы на логические блоки
2. предварительной визуальной нормализации изображения
3. специализированных методов извлечения
4. сама обработка

Программное обеспечения для обработки страниц химических книг

В рамках настоящей работы, опираясь на результаты анализа предметной области и выявленные ограничения существующих подходов, было разработано программное обеспечение для оцифровки страниц химических книг. Функциональная логика системы и основные этапы обработки данных




Рис. 6. UML-диаграмма активностей программы по обработке страниц книг по химии

Fig. 6. UML activity diagram of a program for processing pages of chemistry books

представлены на UML-диаграмме активностей [17] (рис. 6).

Программный комплекс реализован на языке Python, что объясняется его практической востребованностью в задачах обработки изображений и разработки интеллектуальных систем анализа документов. При проектировании использовались паттерны объектно-ориентированного проектирования [23], позволившие структурировать приложение и упростить его дальнейшее расширение. Для обеспечения единообразия и читаемости исходного кода соблюдались рекомендации Python Enhancement Proposals, в частности стандарты оформления кода PEP 8 [24].

Обработка молекул

На основе представления молекул в формате SMILES было разработано программное обеспечение для распознавания химических структур по изображениям. Для решения данной задачи применяются методы OCSR (Optical Chemical Structure Recognition — оптическое распознавание химических структур) [16]. Следует отметить, что OCSR представляет собой не отдельный тип модели, а прикладную задачу, для решения которой используются методы компьютерного зрения и глубокого обучения. В контексте классификации искусственного интеллекта такие методы относятся к области глубокого обучения, представленной на рис. 1 как наиболее внутренний уровень иерархии.

В качестве основы для анализа были рассмотрены три модели, представляющие различные подходы к задаче OCSR:

1. **MolScribe.** MolScribe представляет собой структурно-ориентированный подход к распознаванию химических изображений. Ключевая идея модели заключается в том, что химическую структуру целесообразно рассматривать не как набор независимых символов или линий, а как молекулярный граф, который затем может быть преобразован в строковое представление. В рамках данного подхода изображение сначала переводится в набор визуальных признаков, после чего на их основе восстанавливается структура молекулы [18]. Таким образом, модель определяет положение атомов, типы связей между ними, наличие ароматичности, зарядов и особенности стереохимии. Благодаря этому MolScribe можно отнести к моделям, ориентированным на восстановление химического графа, а не только на последовательное распознавание элементов изображения.
2. **DECIMER (Deep Learning for Chemical Image Recognition).** DECIMER представляет собой модель OCSR, основанную на методах глубокого обучения и обученную на больших объемах синтетически сгенерированных данных [19]. Архи-

тектурно данный подход ориентирован на преобразование изображения химической структуры в строковое представление молекулы. В основе модели лежит схема, в которой сначала из изображения извлекаются визуальные признаки, а затем они используются для генерации последовательности токенов, описывающих химическую структуру. В качестве текстового представления в DECIMER применяется SELFIES, что позволяет повысить устойчивость генерации по сравнению с непосредственным предсказанием SMILES [20]. Существенным достоинством DECIMER является высокая точность распознавания на больших наборах данных, однако по сравнению с графо-ориентированными подходами модель в меньшей степени отражает молекулу именно как графовую структуру, поскольку её основной выход формируется в виде последовательности символов [20].

3. **Qwen3-VL.** Qwen3-VL представляет собой мультимодальную vision-language модель, способную анализировать графическую информацию и формировать текстовое описание содержимого изображения. В контексте задачи OCSR такая модель может рассматриваться как универсальный инструмент визуально-текстового преобразования, потенциально пригодный для интерпретации изображений химических структур. В отличие от специализированных моделей, таких как MolScribe и DECIMER, Qwen3-VL не разрабатывалась исключительно для задач химического распознавания, однако её мультимодальная архитектура позволяет использовать её в качестве сравнительного или вспомогательного подхода при анализе химических изображений [21].

Для применения моделей MolScribe и DECIMER в работе использовались их встроенные механизмы обработки изображений химических струк-

тур. В случае Qwen3-VL взаимодействие с моделью осуществлялось программно через API с использованием системного промпта и набора демонстрационных примеров. Такой подход соответствует парадигме few-shot in-context learning, при которой модель адаптируется к требуемому формату ответа на основе контекста запроса без дополнительного дообучения параметров модели.

Концептуально использование few-shot in-context learning в молекулярных задачах согласуется с результатами работы С. Fifty, J. Leskovec и S. Thrun, где предложен алгоритм CAMP для few-

shot предсказания молекулярных свойств [22]. В данной статье показано, что модель может выполнять предсказание на основе контекста из пар «объект–метка» за один проход, без этапа fine-tuning, и при малом числе примеров превосходит ряд классических meta-learning-подходов [22]. Хотя работа [22] посвящена не распознаванию химических структур по изображениям, а задаче предсказания молекулярных свойств, она подтверждает применимость самой идеи in-context learning в химических задачах при ограниченном числе демонстраций. Поэтому в настоящей работе данный принцип используется как методологическое основание для применения Qwen3-VL в задаче распознавания химических формул по изображениям: модели предоставляется системная инструкция и несколько примеров соответствия между изображением структуры и требуемым текстовым представлением.

Предобработка изображений

Было взят набор изображений молекул из сканированный книг в центральной научной библиотеке Иркутского научного центра Сибирского отделения Российской академии наук было собранно 20 молекул 10 из которых в скелетной нотации, а 10 в подробная нотации.

Список литературы

- [1] Кучуганов, А. В. Методология семантического анализа и поиска графической информации : автореферат диссертации на соискание ученой степени доктора технических наук : специальность 05.13.01 «Системный анализ, управление и обработка информации (в промышленности)» / А. В. Кучуганов. – Ижевск, 2018. – Текст : непосредственный.
- [2] Давлетов, А. Р. Современные методы машинного обучения и технология OCR для автоматизации обработки документов / А. Р. Давлетов. – Текст : электронный // Вестник науки. – 2023. – № 10 (67). – URL: <https://cyberleninka.ru/article/n/sovremennyye-metody-mashinnogo-obucheniya-i-tehnologiya-ocr-dlya-avtomatizatsii-obrabotki-dokumentov> (дата обращения: 22.05.2026).

тектурно данный подход ориентирован на преобразование изображения химической структуры в строковое представление молекулы. В основе модели лежит схема, в которой сначала из изображения извлекаются визуальные призна-

- [3] Раков, Н. С. Машинное зрение / Н. С. Раков, С. В. Пальмов. – Текст : электронный // Форум молодых ученых. – 2018. – № 4 (20). – URL: <https://cyberleninka.ru/article/n/mashinnoe-zrenie> (дата обращения: 22.05.2026).
- [4] Рублевский, Р. Ландшафт основных терминов в области генеративного AI, их взаимосвязь и употребление / Р. Рублевский. – Текст : электронный // Хабр. – 2025. – 25 сент. – URL: <https://habr.com/ru/articles/950600/> (дата обращения: 22.05.2026).
- [5] Akhil, S. Overview of Tesseract OCR engine / S. Akhil. – Текст : электронный // ResearchGate. – 2016. – Dec. – URL: <https://www.researchgate.net/publication/315834331> (дата обращения: 22.05.2026).
- [6] Shen, Z. LayoutParser: A Unified Toolkit for Deep Learning Based Document Image Analysis / Z. Shen [et al.]. – Текст : электронный // arXiv.org. – 2021. – arXiv:2103.15348. – URL: <https://arxiv.org/abs/2103.15348> (дата обращения: 22.05.2026).
- [7] Xu, Y. LayoutLM: Pre-training of Text and Layout for Document Image Understanding / Y. Xu, M. Li, L. Cui [et al.]. – Текст : электронный // arXiv.org. – 2019. – arXiv:1912.13318. – URL: <https://arxiv.org/abs/1912.13318> (дата обращения: 22.05.2026).
- [8] Smith, R. An Overview of the Tesseract OCR Engine / R. Smith // Ninth International Conference on Document Analysis and Recognition (ICDAR 2007). – Washington : IEEE Computer Society, 2007. – Vol. 2. – P. 629–633. – DOI: 10.1109/ICDAR.2007.4376991. – URL: <https://doi.org/10.1109/ICDAR.2007.4376991> (дата обращения: 22.05.2026).
- [9] Trinajstić, N. Chemical Graph Theory / N. Trinajstić. – 2nd ed. – Boca Raton : CRC Press, 1992. – 364 p.
- [10] Warr, W. A. Representation of Chemical Structures / W. A. Warr // Wiley Interdisciplinary Reviews: Computational Molecular Science. – 2011. – Vol. 1, no. 4. – P. 557–579. – DOI: 10.1002/wcms.36.
- [11] Weininger, D. SMILES, a Chemical Language and Information System. 1. Introduction to Methodology and Encoding Rules / D. Weininger // Journal of Chemical Information and Computer Sciences. – 1988. – Vol. 28, no. 1. – P. 31–36. – DOI: 10.1021/ci00057a005.
- [12] Weininger, D. SMILES. 2. Algorithm for Generation of Unique SMILES Notation / D. Weininger, A. Weininger, J. L. Weininger // Journal of Chemical Information and Computer Sciences. – 1989. – Vol. 29, no. 2. – P. 97–101. – DOI: 10.1021/ci00062a008.
- [13] Dalby, A. Description of Several Chemical Structure File Formats Used by Computer Programs Developed at Molecular Design Limited / A. Dalby, J. G. Nourse, W. D. Hounshell [et al.] // Journal of Chemical Information and Computer Sciences. – 1992. – Vol. 32, no. 3. – P. 244–255. – DOI: 10.1021/ci00007a012.
- [14] Heller, S. R. InChI, the IUPAC International Chemical Identifier / S. R. Heller, A. McNaught, I. Pletnev [et al.] // Journal of Cheminformatics. – 2015. – Vol. 7. – Art. 23. – DOI: 10.1186/s13321-015-0068-4.
- [15] O’Boyle, N. M. Towards a Universal SMILES Representation – A Standard Method to Generate Canonical SMILES Based on the InChI / N. M. O’Boyle // Journal of Cheminformatics. – 2012. – Vol. 4. – Art. 22. – DOI: 10.1186/1758-2946-4-22.
- [16] Optical chemical structure recognition. – Текст : электронный // Wikipedia. – URL: https://en.wikipedia.org/wiki/Optical_chemical_structure_recognition (дата обращения: 22.05.2026).
- [17] OMG Unified Modeling Language (OMG UML), Version 2.5.1 / Object Management Group. – 2017. – URL: <https://www.omg.org/spec/UML/2.5.1/PDF> (дата обращения: 22.05.2026).
- [18] MolScribe: Robust Molecular Structure Recognition with Image-To-Graph Generation / Y. Qian, J. Guo, Z. Tu [et al.]. – Текст : электронный // arXiv.org. – 2022. – arXiv:2205.14311. – URL: <https://arxiv.org/pdf/2205.14311> (дата обращения: 22.05.2026).
- [19] Rajan, K. DECIMER 1.0: deep learning for chemical image recognition using transformers / K. Rajan [et al.]. – Текст : электронный // ResearchGate. – 2021. – Aug. – URL: https://www.researchgate.net/publication/353957394_DECIMER_1.0_deep_learning_for_chemical_image_recognition_using_transformers (дата обращения: 22.05.2026).
- [20] Rajan, K. DECIMER 1.0: deep learning for chemical image recognition using transformers / K. Rajan, A. Zielesny, C. Steinbeck. – Текст : электронный // Journal of Cheminformatics. – 2021. – Vol. 13. – DOI: 10.1186/s13321-021-00538-8. – URL: <https://doi.org/10.1186/s13321-021-00538-8> (дата обращения: 22.05.2026).

- [21] Qwen Team. Qwen3-VL Technical Report / Qwen Team. – Текст : электронный // arXiv.org. – 2025. – arXiv:2511.21631. – URL: <https://arxiv.org/abs/2511.21631> (дата обращения: 22.05.2026).
- [22] Fifty, C. In-Context Learning for Few-Shot Molecular Property Prediction / C. Fifty, J. Leskovec, S. Thrun. – Текст : электронный // arXiv.org. – 2023. – arXiv:2310.08863. – URL: <https://arxiv.org/abs/2310.08863> (дата обращения: 22.05.2026).
- [23] Gamma, E. Design Patterns: Elements of Reusable Object-Oriented Software / E. Gamma, R. Helm, R. Johnson, J. Vlissides. – Reading : Addison-Wesley, 1995. – 395 p. – ISBN 0-201-63361-2. – Текст : непосредственный.
- [24] van Rossum, G. PEP 8 – Style Guide for Python Code / G. van Rossum, B. Warsaw, A. Coghlan. – Текст : электронный // Python.org. – URL: <https://peps.python.org/pep-0008/> (дата обращения: 23.05.2026).

References

- [1] Kuchuganov, A. V. Methodology of semantic analysis and search for graphic information: abstract of the dissertation for the degree of Doctor of Technical Sciences: specialty 05.13.01 “System analysis, management and information processing (in industry)” / A. V. Kuchuganov. – Izhevsk, 2018. – Text: direct.
- [2] Davletov, A. R. Modern methods of machine learning and OCR technology for automating document processing / A. R. Davletov. – Text: electronic // Bulletin of Science. – 2023. – No. 10 (67). – URL: <https://cyberleninka.ru/article/n/sovremennye-metody-mashinnogo-obucheniya-i-tehnologiya-ocr-dlya-avtomatizatsii-obrabotki-dokumentov> (date of access: 05/22/2026).
- [3] Rakov, N. S. Machine vision / N. S. Rakov, S. V. Palmov. – Text: electronic // Forum of young scientists. – 2018. – No. 4 (20). – URL: <https://cyberleninka.ru/article/n/mashinnoe-zrenie> (date of access: 05/22/2026).
- [4] Rublevsky, R. Landscape of basic terms in the field of generative AI, their relationship and use / R. Rublevsky. – Text: electronic // Habr. – 2025. – September 25 – URL: <https://habr.com/ru/articles/950600/> (access date: 05/22/2026).
- [5] Akhil, S. Overview of Tesseract OCR engine / S. Akhil. – Text: electronic // ResearchGate. – 2016. – Dec. – URL: <https://www.researchgate.net/publication/315834331> (access date: 05/22/2026).
- [6] Shen, Z. LayoutParser: A Unified Toolkit for Deep Learning Based Document Image Analysis / Z. Shen [et al.]. – Text: electronic // arXiv.org. – 2021. – arXiv:2103.15348. – URL: <https://arxiv.org/abs/2103.15348> (access date: 05/22/2026).
- [7] Xu, Y. LayoutLM: Pre-training of Text and Layout for Document Image Understanding / Y. Xu, M. Li, L. Cui [et al.]. – Text: electronic // arXiv.org. – 2019. – arXiv:1912.13318. – URL: <https://arxiv.org/abs/1912.13318> (access date: 05/22/2026).
- [8] Smith, R. An Overview of the Tesseract OCR Engine / R. Smith // Ninth International Conference on Document Analysis and Recognition (ICDAR 2007). – Washington: IEEE Computer Society, 2007. – Vol. 2. – P. 629–633. – DOI: 10.1109/ICDAR.2007.4376991. – URL: <https://doi.org/10.1109/ICDAR.2007.4376991> (access date: 05.22.2026).
- [9] Trinajstić, N. Chemical Graph Theory / N. Trinajstić. – 2nd ed. – Boca Raton : CRC Press, 1992. – 364 p.
- [10] Warr, W. A. Representation of Chemical Structures / W. A. Warr // Wiley Interdisciplinary Reviews: Computational Molecular Science. – 2011. – Vol. 1, no. 4. – P. 557–579. – DOI: 10.1002/wcms.36.
- [11] Weininger, D. SMILES, a Chemical Language and Information System. 1. Introduction to Methodology and Encoding Rules / D. Weininger // Journal of Chemical Information and Computer Sciences. – 1988. – Vol. 28, no. 1. – P. 31–36. – DOI: 10.1021/ci00057a005.
- [12] Weininger, D. SMILES. 2. Algorithm for Generation of Unique SMILES Notation / D. Weininger, A. Weininger, J. L. Weininger // Journal of Chemical Information and Computer Sciences. – 1989. – Vol. 29, no. 2. – P. 97–101. – DOI: 10.1021/ci00062a008.
- [13] Dalby, A. Description of Several Chemical Structure File Formats Used by Computer Programs Developed at Molecular Design Limited / A. Dalby, J. G. Nourse, W. D. Hounshell [et al.] // Journal of Chemical Information and Computer Sciences. – 1992. – Vol. 32, no. 3. – P. 244–255. – DOI: 10.1021/ci00007a012.
- [14] Heller, S. R. InChI, the IUPAC International Chemical Identifier / S. R. Heller, A. McNaught, I. Pletnev [et al.] // Journal of Cheminformatics. – 2015. – Vol. 7. – Art. 23. – DOI: 10.1186/s13321-015-0068-4.