

ОЦИФРОВКА ХИМИЧЕСКИХ КНИГ С ИСПОЛЬЗОВАНИЕМ МАШИННОГО ЗРЕНИЯ

Алакшин М. С.¹, Рыбак А. В.¹, Такачёв Д. А.¹, Трофимов И. Л.^{2,3}

¹ Федеральное государственное бюджетное образовательное учреждение высшего образования «Иркутский государственный университет»

² Федеральный исследовательский центр «Иркутский институт химии им. А. Е. Фаворского Сибирского отделения Российской академии наук», г. Иркутск

³ Государственная публичная научно-техническая библиотека Сибирского отделения Российской академии наук, г. Новосибирск

Резюме

В статье рассматривается трансформация роли современных библиотек в условиях цифровой неопределенности и стремительного развития технологий искусственного интеллекта. ...

Ключевые слова

искусственный интеллект, цифровая неопределенность, информационный шум, генеративные нейронные сети, интеллектуальная поисковая система, Retrieval Augmented Generation, семантический поиск, верификация, научное наследие, большие языковые модели

Введение

Знания, содержащиеся в химических книгах, монографиях и архивных выпусках журналов, сохраняют высокую научную и практическую ценность: в них зафиксированы методики синтеза, экспериментальные наблюдения, справочные сведения о веществах и их свойствах, а также контекст, необходимый для воспроизводимости результатов. При этом существенная часть такого корпуса литературы до сих пор существует в виде физических изданий или в виде скан-копий, которые удобны для чтения человеком, но плохо приспособлены для автоматизированного анализа и интеграции в современные информационные системы.

На фоне развития информационных технологий и интеллектуального поиска становится актуальной задача извлечения знаний из химических книг с последующей структуризацией и верификацией. Однако на практике оцифровка часто сводится к распознаванию текста (OCR) и формированию «поискового PDF» [2], что позволяет выполнять лишь поверхностный текстовый поиск. В химической литературе значимая часть информации представлена не в виде текста, а в виде графических объектов: структурных формул, схем реакций. Если эти элементы не переводятся в машинно-обрабатываемые представления, то большая доля смысла документа остается вне цифрового контура и фактически недоступна для алгоритмов поиска, сопоставления и анализа [1].

В данной работе рассматривается подход к ком-

плексной оцифровке химической литературы, ориентированный не только на извлечение текстового слоя, но и на распознавание и структурирование графической химической информации, что позволяет разработать систему интеллектуального поиска по книгам. Подходы к оцифровке книг

Машинное зрение и проблемы с извлечением данных из сканированных книг

Машинное зрение (Computer Vision, CV) представляет собой область искусственного интеллекта, изучающую методы автоматического анализа изображений и видео с целью извлечения из них семантически значимой информации [?]. В контексте оцифровки научной литературы CV выступает технологической основой направления анализа изображений документов, где объектом обработки является страница, содержащая текст, формулы. В отличие от классических задач компьютерного зрения (распознавание объектов на фотографиях), для документов критично учитывать регулярную структуру страницы, взаимное расположение блоков и качество исходного скана, поскольку даже небольшие дефекты заметно ухудшают последующие этапы распознавания.

Практическая необходимость применения CV в рамках данной работы обусловлена тем, что большинство архивных химических книг и сканированных материалов характеризуются неоднородным качеством: встречаются шум, перекося страниц, размытие, неравномерная засветка, артефакты компрессии, следы сгиба, а также вариативность шрифтов и верстки.

Эти факторы напрямую влияют на точность OCR и на стабильность выделения графических объектов (структурных формул и схем реакций). Поэтому задача комплексной оцифровки требует не только распознавания символов, но и предварительной визуальной нормализации изображения, сегментации страницы на логические блоки и специализированных методов извлечения химической графики — то есть полного конвейера, опирающегося на инструменты и модели машинного зрения.

Список литературы

- [1] Кучуганов, А. В. Методология семантического анализа и поиска графической информации : автореферат диссертации на соискание ученой степени доктора технических наук : специальность 05.13.01 «Системный анализ, управление и обработка информации (в промышленности)» / А. В. Кучуганов. – Ижевск, 2018. – Текст : непосредственный.
- [2] Давлетов, А. Р. Современные методы машинного обучения и технология OCR для автоматизации обработки документов / А. Р. Давлетов. – Текст : электронный // Вестник науки. – 2023. – № 10 (67). – URL: <https://cyberleninka.ru/article/n/sovremennye-metody-mashinnogo-obucheniya-i-tehnologiya-ocr-dlya-avtomatizatsii-obrabotki-dokumentov> (дата обращения: 22.05.2026).
- [3] Раков, Н. С. Машинное зрение / Н. С. Раков, С. В. Пальмов. – Текст : электронный // Форум молодых ученых. – 2018. – № 4 (20). – URL: <https://cyberleninka.ru/article/n/mashinnoe-zrenie> (дата обращения: 22.05.2026).