

ОЦИФРОВКА ХИМИЧЕСКИХ КНИГ С ИСПОЛЬЗОВАНИЕМ МАШИННОГО ЗРЕНИЯ

Алакшин М. С.¹, Рыбак А. В.¹, Такачёв Д. А.¹, Трофимов И. Л.^{2,3}

¹ Федеральное государственное бюджетное образовательное учреждение высшего образования «Иркутский государственный университет»

² Федеральный исследовательский центр «Иркутский институт химии им. А. Е. Фаворского Сибирского отделения Российской академии наук», г. Иркутск

³ Государственная публичная научно-техническая библиотека Сибирского отделения Российской академии наук, г. Новосибирск

Резюме

В статье рассматривается трансформация роли современных библиотек в условиях цифровой неопределенности и стремительного развития технологий искусственного интеллекта. ...

Ключевые слова

искусственный интеллект, цифровая неопределенность, информационный шум, генеративные нейронные сети, интеллектуальная поисковая система, Retrieval Augmented Generation, семантический поиск, верификация, научное наследие, большие языковые модели

Введение

Знания, содержащиеся в химических книгах, монографиях и архивных выпусках журналов, сохраняют высокую научную и практическую ценность: в них зафиксированы методики синтеза, экспериментальные наблюдения, справочные сведения о веществах и их свойствах, а также контекст, необходимый для воспроизводимости результатов. При этом существенная часть такого корпуса литературы до сих пор существует в виде физических изданий или в виде скан-копий, которые удобны для чтения человеком, но плохо приспособлены для автоматизированного анализа и интеграции в современные информационные системы.

На фоне развития информационных технологий и интеллектуального поиска становится актуальной задача извлечения знаний из химических книг с последующей структуризацией и верификацией. Однако на практике оцифровка часто сводится к распознаванию текста (OCR) и формированию «поискового PDF» [2], что позволяет выполнять лишь поверхностный текстовый поиск. В химической литературе значимая часть информации представлена не в виде текста, а в виде графических объектов: структурных формул, схем реакций. Если эти элементы не переводятся в машинно-обрабатываемые представления, то большая доля смысла документа остается вне цифрового контура и фактически недоступна для алгоритмов поиска, сопоставления и анализа [1].

В данной работе рассматривается подход к ком-

плексной оцифровке химической литературы, ориентированный не только на извлечение текстового слоя, но и на распознавание и структурирование графической химической информации, что позволяет разработать систему интеллектуального поиска по книгам.

Машинное зрение и проблемы с извлечением данных из сканированных книг

Машинное зрение (Computer Vision, CV) представляет собой область искусственного интеллекта, изучающую методы автоматического анализа изображений и видео с целью извлечения из них семантически значимой информации [3]. В работе [4] машинное зрение выделяется как внешнее кольцо в общей классификации искусственного интеллекта (см. рис. 1).

Практическая необходимость применения методов компьютерного зрения в рамках данной работы обусловлена тем, что автоматизация обработки документов требует не только распознавания текста, но и предварительного анализа изображения документа. Как показано в работе А. Р. Давлетова, современные OCR-системы решают задачи предварительной обработки изображения, обнаружения текстовых областей, анализа компоновки страницы и последующего распознавания символов и слов [2]. Такой подход позволяет преобразовывать сканированные документы, PDF-файлы и изображения, полученные при сканировании, в машиночитаемый текст, пригодный для поиска, редактирования и дальнейшего извлечения данных [2].




Рис. 1. Классификация искусственного интеллекта

По сравнению с ручной обработкой автоматизированный подход сокращает время ввода данных, снижает влияние человеческого фактора, уменьшает количество ошибок и упрощает поиск и доступ к информации [2]. Кроме того, в рассматриваемой статье отмечается, что применение методов машинного обучения совместно с OCR позволяет не только конвертировать изображение в текст, но и извлекать из него полезные данные, а в практических сценариях такие решения демонстрируют высокую точность и значительный уровень автоматизации документооборота [2].

Для распознавания документов критично учитывать регулярную структуру страницы и взаимное расположение блоков, поскольку страница научного документа представляет собой не просто непрерывное изображение текста, а композицию из различных смысловых областей: заголовков, основного текста, подписей к рисункам, таблиц, формул, схем, иллюстраций и служебных элементов [7].

При этом качество исходного скана также существенно влияет на надежность распознавания: шум, перекося, неравномерная засветка и другие дефекты заметно ухудшают последующие этапы OCR и анализа структуры документа [8].

Эта задача относится к направлению анализа изображений документов и играет роль промежуточного звена между общими методами машинного зрения и прикладными системами OCR. Если этап сегментации пропускается или выполняется неточно, то OCR-система может воспринимать графические объекты как текст, объединять соседние колонки, терять подписи к рисункам, ошибочно включать части формул в текстовый поток или, наоборот, игнориро-

вать важные текстовые фрагменты. Для химической литературы данная проблема особенно существенна, поскольку на одной странице часто одновременно присутствуют обычный текст, структурные химические формулы, схемы реакций, таблицы и обозначения, различающиеся как по визуальной форме, так и по способу дальнейшей обработки.

С практической точки зрения сегментация страницы позволяет перейти от обработки документа как единого изображения к обработке набора специализированных областей. После выделения таких областей (см. рис. 2) к каждой из них может быть применен собственный алгоритм: к текстовым блокам — OCR, к структурным формулам — методы распознавания химической графики, к таблицам — алгоритмы восстановления табличной структуры, к рисункам и схемам — отдельные процедуры анализа изображений. Таким образом, сегментация формирует основу всего конвейера оцифровки: *страница целиком* → *выделение блоков* → *специализированное распознавание* → *структурированное представление знаний*.




Рис. 2. Схема сегментации

Современные подходы к анализу макета документа опираются на методы глубокого обучения, позволяющие автоматически выделять типовые области страницы и учитывать их пространственный контекст. В работе P. Renton, P. Chatto и соавторов представлен инструмент *LayoutParser*, ориенти-

рованный на унифицированный анализ структуры документов на основе моделей глубокого обучения, что подтверждает практическую значимость этапа предварительной сегментации для дальнейшего извлечения информации из сложных страниц [6]. Использование подобных подходов особенно актуально для оцифровки архивных и сканированных книг, где вариативность верстки, качество печати и наличие графических элементов делают задачу прямого распознавания без предварительного структурного анализа существенно менее надежной.

Большинство архивных химических книг и сканированных материалов характеризуются неоднородным качеством. В работе [5] выделялись следующие проблемы качества сканированных книг:

- Низкое разрешение / размытость (рис. 3 а)
- Шум, зернистость, артефакты сжатия (рис. 3 б)
- Неравномерная заселённость / тени (рис. 3 в)
- Ориентация страницы с малым поворотом (рис. 3 д)




Рис. 3. Пример плохого качества сканированных книг
 а) Размытость; б) Шум; в) Неравномерная заселённость; г) Ориентация страницы с малым поворотом.

Эти факторы напрямую влияют на точность распознавания как и графических формул и реакций так и текста. Поэтому перед обработкой самой OCR необходимо сделать пред обработку и нормализацию изображения.

Поэтому задача комплексной оцифровки требует:

1. сегментации страницы на логические блоки

2. предварительной визуальной нормализации изображения
3. специализированных методов извлечения
4. сама обработка

Список литературы

- [1] Кучуганов, А. В. Методология семантического анализа и поиска графической информации : автореферат диссертации на соискание ученой степени доктора технических наук : специальность 05.13.01 «Системный анализ, управление и обработка информации (в промышленности)» / А. В. Кучуганов. – Ижевск, 2018. – Текст : непосредственный.
- [2] Давлетов, А. Р. Современные методы машинного обучения и технология OCR для автоматизации обработки документов / А. Р. Давлетов. – Текст : электронный // Вестник науки. – 2023. – № 10 (67). – URL: <https://cyberleninka.ru/article/n/sovremennyye-metody-mashinnogo-obucheniya-i-tehnologiya-ocr-dlya-avtomatizatsii-obrabotki-dokumentov> (дата обращения: 22.05.2026).
- [3] Раков, Н. С. Машинное зрение / Н. С. Раков, С. В. Пальмов. – Текст : электронный // Форум молодых ученых. – 2018. – № 4 (20). – URL: <https://cyberleninka.ru/article/n/mashinnoe-zrenie> (дата обращения: 22.05.2026).
- [4] Рублевский, Р. Ландшафт основных терминов в области генеративного AI, их взаимосвязь и употребление / Р. Рублевский. – Текст : электронный // Хабр. – 2025. – 25 сент. – URL: <https://habr.com/ru/articles/950600/> (дата обращения: 22.05.2026).
- [5] Akhil, S. Overview of Tesseract OCR engine / S. Akhil. – Текст : электронный // ResearchGate. – 2016. – Dec. – URL: <https://www.researchgate.net/publication/315834331> (дата обращения: 22.05.2026).
- [6] Shen, Z. LayoutParser: A Unified Toolkit for Deep Learning Based Document Image Analysis / Z. Shen [et al.]. – Текст : электронный // arXiv.org. – 2021. – arXiv:2103.15348. – URL: <https://arxiv.org/abs/2103.15348> (дата обращения: 22.05.2026).
- [7] Xu, Y. LayoutLM: Pre-training of Text and Layout for Document Image Understanding / Y. Xu, M. Li, L. Cui [et al.]. – Текст : электронный // arXiv.org. – 2019. – arXiv:1912.13318. – URL: <https://arxiv.org/abs/1912.13318> (дата обращения: 22.05.2026).
- [8] Smith, R. An Overview of the Tesseract OCR Engine / R. Smith // Ninth International Conference on Document

Analysis and Recognition (ICDAR 2007). – Washington : IEEE Computer Society, 2007. – Vol. 2. – P. 629–633. – DOI: 10.1109/ICDAR.2007.4376991. – URL: <https://doi.org/10.1109/ICDAR.2007.4376991> (дата обращения: 22.05.2026).