

ОЦИФРОВКА ХИМИЧЕСКИХ КНИГ С ИСПОЛЬЗОВАНИЕМ МАШИННОГО ЗРЕНИЯ

Алакшин М. С.^{1,2}, Рыбак А. В.^{1,2}, Такачев Д. А.^{1,2}, Трофимов И. Л.^{2,3}

¹ Федеральное государственное бюджетное образовательное учреждение высшего образования «Иркутский государственный университет»

² Федеральный исследовательский центр «Иркутский институт химии им. А. Е. Фаворского Сибирского отделения Российской академии наук», г. Иркутск

³ Государственная публичная научно-техническая библиотека Сибирского отделения Российской академии наук, г. Новосибирск

Резюме

В статье рассматривается трансформация роли современных библиотек в условиях цифровой неопределенности и стремительного развития технологий искусственного интеллекта. ...

Ключевые слова

искусственный интеллект, цифровая неопределенность, информационный шум, генеративные нейронные сети, интеллектуальная поисковая система, Retrieval Augmented Generation, семантический поиск, верификация, научное наследие, большие языковые модели

DIGITIZATION OF CHEMISTRY BOOKS USING MACHINE VISION

Alakshin M. S.^{1,2}, Rybak A. V.^{1,2}, Takachev D. A.^{1,2}, Trofimov I. L.^{2,3}

¹ Federal State Budgetary Educational Institution of Higher Education "Irkutsk State University"

² Federal Research Center "Irkutsk Institute of Chemistry named after A. E. Favorsky, Siberian Branch of the Russian Academy of Sciences Irkutsk

³ State Public Scientific and Technical Library of the Siberian Branch of the Russian Academy of Sciences, Novosibirsk

Abstract

The article examines the transformation of the role of modern libraries in conditions of digital uncertainty and the rapid development of artificial intelligence technologies. ...

Keywords

artificial intelligence, digital uncertainty, information noise, generative neural networks, intelligent search system, Retrieval Augmented Generation, semantic search, verification, scientific heritage, large language models

Введение

Знания, содержащиеся в химических книгах, монографиях и архивных выпусках журналов, сохраняют высокую научную и практическую ценность: в них зафиксированы методики синтеза, экспериментальные наблюдения, справочные сведения о веществах и их свойствах, а также контекст, необходимый для воспроизводимости результатов. При этом существенная часть такого корпуса литературы до сих пор существует в виде физических изданий или в виде скан-копий, которые удобны для чтения человеком, но плохо приспособлены для автоматизированного анализа и интеграции в современные информационные системы.

На фоне развития информационных технологий и интеллектуального поиска становится актуаль-

ной задача извлечения знаний из химических книг с последующей структуризацией и верификацией. Однако на практике оцифровка часто сводится к распознаванию текста (OCR) и формированию «поискового PDF» [2], что позволяет выполнять лишь поверхностный текстовый поиск. В химической литературе значимая часть информации представлена не в виде текста, а в виде графических объектов: структурных формул, схем реакций. Если эти элементы не переводятся в машинно-обрабатываемые представления, то большая доля смысла документа остается вне цифрового контура и фактически недоступна для алгоритмов поиска, сопоставления и анализа [1].

В данной работе рассматривается подход к комплексной оцифровке химической литературы, ориентированный не только на извлечение текстового




Рис. 1. Классификация искусственного интеллекта

Fig. 1. Classification of artificial intelligence

сложно, но и на распознавание и структурирование графической химической информации, что позволяет разработать систему интеллектуального поиска по книгам.

Машинное зрение и проблемы с извлечением данных из сканированных книг

Машинное зрение (Computer Vision, CV) представляет собой область искусственного интеллекта, изучающую методы автоматического анализа изображений и видео с целью извлечения из них семантически значимой информации [3]. В работе [4] машинное зрение выделяется как внешнее кольцо в общей классификации искусственного интеллекта (см. рис. 1). Практическая необходимость применения методов компьютерного зрения в рамках данной работы обусловлена тем, что автоматизация обработки документов требует не только распознавания текста, но и предварительного анализа изображения документа. Как показано в работе А. Р. Давлетова, современные OCR-системы решают задачи предварительной обработки изображения, обнаружения текстовых областей, анализа компоновки страницы и последующего распознавания символов и слов [2]. Такой подход позволяет преобразовывать сканированные документы, PDF-файлы и изображения, полученные при сканировании, в машиночитаемый текст, пригодный для поиска, редактирования и дальнейшего извлечения данных [2].

По сравнению с ручной обработкой автоматизированный подход сокращает время ввода данных, снижает влияние человеческого фактора, уменьшает количество ошибок и упрощает поиск и доступ к информации [2]. Кроме того, в рассматриваемой статье отмечается, что применение методов машинного обучения совместно с OCR позволяет не только конвертировать изображение в текст, но и извлекать из него полезные данные, а в практических сценариях такие решения демонстрируют высокую точность и значительный уровень автоматизации документооборота [2].

Сегментация страницы

Для распознавания документов критично учитывать регулярную структуру страницы и взаимное расположение блоков, поскольку страница научного документа представляет собой не просто непрерывное изображение текста, а композицию из различных смысловых областей: заголовков, основного текста, подписей к рисункам, таблиц, формул, схем, иллюстраций и служебных элементов [7].

При этом качество исходного скана также существенно влияет на надежность распознавания: шум, перекося, неравномерная засветка и другие дефекты заметно ухудшают последующие этапы OCR и анализа структуры документа [8].

Эта задача относится к направлению анализа изображений документов и играет роль промежу-




Рис. 2. Схема сегментации

Fig. 2. Segmentation scheme

точного звена между общими методами машинного зрения и прикладными системами OCR. Если этап сегментации пропускается или выполняется неточно, то OCR-система может воспринимать графические объекты как текст, объединять соседние колонки, терять подписи к рисункам, ошибочно включать части формул в текстовый поток или, наоборот, игнорировать важные текстовые фрагменты. Для химической литературы данная проблема особенно существенна, поскольку на одной странице часто одновременно присутствуют обычный текст, структурные химические формулы, схемы реакций, таблицы и обозначения, различающиеся как по визуальной форме, так и по способу дальнейшей обработки.

С практической точки зрения сегментация страницы позволяет перейти от обработки документа как единого изображения к обработке набора специализированных областей. После выделения таких областей (см. рис. 2) к каждой из них может быть применен собственный алгоритм: к текстовым блокам — OCR, к структурным формулам — методы распознавания химической графики, к таблицам — алгоритмы восстановления табличной структуры, к рисункам и схемам — отдельные процедуры анализа изображений. Таким образом, сегментация формирует основу всего конвейера оцифровки: *страница целиком* → *выделение блоков* → *специализированное распознавание* → *структурированное представление знаний*.

Современные подходы к анализу макета документа опираются на методы глубокого обучения, позволяющие автоматически выделять типовые об-

ласти страницы и учитывать их пространственный контекст. В работе P. Renton, P. Chatto и соавторов представлен инструмент *LayoutParser*, ориентированный на унифицированный анализ структуры документов на основе моделей глубокого обучения, что подтверждает практическую значимость этапа предварительной сегментации для дальнейшего извлечения информации из сложных страниц [6]. Использование подобных подходов особенно актуально для оцифровки архивных и сканированных книг, где вариативность верстки, качество печати и наличие графических элементов делают задачу прямого распознавания без предварительного структурного анализа существенно менее надежной.

Предобработка изображения

Большинство архивных химических книг и сканированных материалов характеризуются неоднородным качеством. В работе [5] выделялись следующие проблемы качества сканированных книг:

- Низкое разрешение / размытость (рис. 3 а)
- Шум, зернистость, артефакты сжатия (рис. 3 б)
- Неравномерная засветлённость / тени (рис. 3 с)
- Ориентация страницы с малым поворотом (рис. 3 д)

Эти факторы напрямую влияют на точность распознавания как и графических формул и реакций так и текста. Поэтому перед обработкой самой OCR необходимо сделать пред обработку и нормализацию изображения.

a)

b)

c)

d)

Рис. 3. Пример плохого качества сканированных книг а) Размытость; б) Шум; в) Неравномерная засветлённость; д) Ориентация страницы с малым поворотом.

Fig. 3. An example of poor quality scanned books a) Blur; b) Noise; c) Uneven illumination; d) Page orientation with low rotation.

Проблемы с преобразование химических реакций и молекул в машинчитаемый вид

Химические формулы и схемы реакций существенно сложнее для автоматической обработки, чем обычный текст, поскольку их естественное представление является не линейной последовательностью символов, а графовой структурой. В молекулярном графе вершины соответствуют атомам, а рёбра — химическим связям; реакция, в свою очередь, может рассматриваться как преобразование одного множества молекулярных графов в другое. Поэтому химическая запись несёт смысл не только через набор символов, но и через топологию, тип связей, ароматичность, заряды, стереохимию и пространственные отношения между фрагментами структуры. Именно это отличает задачу распознавания формул от классического OCR: если для текста ключевой является последовательность символов, то для химической формулы необходимо восстановить структуру графа и затем представить её в форме, пригодной для хранения, поиска и последующего анализа [9, 10].

Дополнительную сложность создаёт то, что в химической литературе используются по меньшей мере две распространённые графические нотации записи молекул: подробная (развёрнутая) и скелетная (см. рис. 4). В подробной записи явно показываются атомы и значительная часть связей, что облегчает интерпретацию человеком, но увеличивает визуальную

насыщенность изображения. В скелетной нотации, напротив, большинство атомов углерода и связанные с ними атомы водорода опускаются, а углеродный каркас кодируется линиями, вершины и концы которых интерпретируются как атомы углерода; гетероатомы, кратные связи, заряды и функциональные группы отображаются явно. Именно скелетная запись наиболее типична для органической химии и научных публикаций, однако она значительно усложняет автоматическое распознавание, так как часть информации в ней задаётся по соглашению, а не прописывается явно. В результате алгоритм должен не просто “увидеть линии”, но восстановить скрытые атомы, валентности и химически допустимую структуру [10].

После распознавания графическое изображение молекулы должно быть переведено в машинно-обрабатываемый формат. В современной хемоинформатике для этого используются несколько основных способов представления структур. К числу наиболее распространённых относятся SMILES (Simplified Molecular Input Line Entry System), InChI (International Chemical Identifier), файловые форматы Molfile и SDF, XML-ориентированный CML (Chemical Markup Language), а для реакций — RXNfile, RDF, а также строковые языки наподобие SMIRKS для описания реакционных преобразований. Эти форматы различаются по назначению: одни удобны для компактной линейной записи и поиска, другие — для




Рис. 4. Пример разных нотаций а) подробная; б) скелетная.
Fig. 4. Example of different notations a) detailed; b) skeletal.

хранения полной структурной информации, координат, метаданных и реакционных схем. Обзор таких представлений и их роли в химической информатике приведён в работах по компьютерному представлению химических структур и форматам химических данных [10, 13, 14].

В данной работе в качестве основного текстового представления структуры выбран формат SMILES, предложенный как компактный язык линейной записи молекул [11, 12]. Его выбор обусловлен несколькими причинами. Во-первых, SMILES является кратким и человекочитаемым: одна молекула кодируется строкой, удобной для хранения в базах данных, индексации, поиска и передачи между программными компонентами. Во-вторых, SMILES широко поддерживается в современных библиотеках и инструментах хемоинформатики, что облегчает интеграцию распознанных структур в конвейер обработки, верификации и поиска. В-третьих, SMILES особенно удобен в задачах, где химическая информация должна быть включена в текстовый или гибридный контур обработки — например, при индексировании документов, построении RAG-систем, текстовом сравнении структур или использовании языковых моделей. В отличие от графического изображения, строка SMILES может быть быстро сопоставлена, нормализована, проверена на корректность и преобразована обратно в молекулярный граф, что делает её практическим компромиссом между компактностью, выразительностью и вычислительной удобностью [10, 11].

При этом важным свойством SMILES является неоднозначность представления (см. рис. 5): одна и та же молекула может быть записана несколькими различными, но эквивалентными строками. Это связано с тем, что линейная запись строится на основе

обхода графа, а один и тот же граф допускает разные порядки обхода, разные точки старта, разные способы нумерации циклов, а также различные варианты явного или неявного задания некоторых структурных особенностей. Например, одна и та же структура может быть записана через разные эквивалентные последовательности ветвлений или с использованием разных соглашений для ароматических фрагментов. В задачах хранения и поиска это создаёт проблему: если использовать произвольный SMILES, то идентичные молекулы могут быть представлены разными строками, что затрудняет дедупликацию, построение индексов и сопоставление результатов распознавания [12].

Для устранения этой неоднозначности используется канонический SMILES, то есть строковое представление, которое строится по детерминированному алгоритму канонизации и назначает данной структуре единственную «стандартную» форму записи в рамках конкретной программной системы. Идея канонизации состоит в том, чтобы сначала определить уникальный порядок атомов на основе свойств графа, а затем сгенерировать строку по фиксированным правилам обхода. Это позволяет переводить множество эквивалентных SMILES-представлений одной и той же молекулы к одной нормализованной форме. Однако важно учитывать, что канонический SMILES не является абсолютно универсальным мировым стандартом: разные программные пакеты могут использовать разные алгоритмы канонизации, поэтому канонические строки, полученные, например, в двух различных хемоинформатических библиотеках, могут отличаться при сохранении химической эквивалентности. Тем не менее в рамках одного конвейера обработки канонический SMILES является чрезвычайно полезным инструментом, поскольку обеспечивает




Рис. 5. пример неоднозначного представление форму
Fig. 5. example of ambiguous form representation

нормализацию результатов распознавания, устойчивое сравнение структур и корректную интеграцию извлечённых данных в базы знаний и поисковые индексы [12, 14, 15]. Таким образом, выбор SMILES в сочетании с последующей канонизацией представляет собой практически оправданное решение для задач оцифровки и структурирования химической литературы.

Поэтому задача комплексной оцифровки требует:

1. сегментации страницы на логические блоки
2. предварительной визуальной нормализации изображения
3. специализированных методов извлечения
4. сама обработка

Список литературы

- [1] Кучуганов, А. В. Методология семантического анализа и поиска графической информации : автореферат диссертации на соискание ученой степени доктора технических наук : специальность 05.13.01 «Системный анализ, управление и обработка информации (в промышленности)» / А. В. Кучуганов. – Ижевск, 2018. – Текст : непосредственный.
- [2] Давлетов, А. Р. Современные методы машинного обучения и технология OCR для автоматизации обработки документов / А. Р. Давлетов. – Текст : электронный // Вестник науки. – 2023. – № 10 (67). – URL: <https://cyberleninka.ru/article/n/sovremennyye-metody-mashinnogo-obucheniya-i-tehnologiya-ocr-dlya-avtomatizatsii-obrabotki-dokumentov> (дата обращения: 22.05.2026).
- [3] Раков, Н. С. Машинное зрение / Н. С. Раков, С. В. Пальмов. – Текст : электронный // Форум молодых ученых. – 2018. – № 4 (20). – URL: <https://cyberleninka.ru/article/n/mashinnoe-zrenie> (дата обращения: 22.05.2026).
- [4] Рублевский, Р. Ландшафт основных терминов в области генеративного AI, их взаимосвязь и употребление / Р. Рублевский. – Текст : электронный // Хабр. – 2025. – 25 сент. – URL: <https://habr.com/ru/articles/950600/> (дата обращения: 22.05.2026).
- [5] Akhil, S. Overview of Tesseract OCR engine / S. Akhil. – Текст : электронный // ResearchGate. – 2016. – Dec. – URL: <https://www.researchgate.net/publication/315834331> (дата обращения: 22.05.2026).
- [6] Shen, Z. LayoutParser: A Unified Toolkit for Deep Learning Based Document Image Analysis / Z. Shen [et al.]. – Текст : электронный // arXiv.org. – 2021. – arXiv:2103.15348. – URL: <https://arxiv.org/abs/2103.15348> (дата обращения: 22.05.2026).

- [7] Xu, Y. LayoutLM: Pre-training of Text and Layout for Document Image Understanding / Y. Xu, M. Li, L. Cui [et al.]. – Текст : электронный // arXiv.org. – 2019. – arXiv:1912.13318. – URL: <https://arxiv.org/abs/1912.13318> (дата обращения: 22.05.2026).
- [8] Smith, R. An Overview of the Tesseract OCR Engine / R. Smith // Ninth International Conference on Document Analysis and Recognition (ICDAR 2007). – Washington : IEEE Computer Society, 2007. – Vol. 2. – P. 629–633. – DOI: 10.1109/ICDAR.2007.4376991. – URL: <https://doi.org/10.1109/ICDAR.2007.4376991> (дата обращения: 22.05.2026).
- [9] Trinajstić, N. Chemical Graph Theory / N. Trinajstić. – 2nd ed. – Boca Raton : CRC Press, 1992. – 364 p.
- [10] Warr, W. A. Representation of Chemical Structures / W. A. Warr // Wiley Interdisciplinary Reviews: Computational Molecular Science. – 2011. – Vol. 1, no. 4. – P. 557–579. – DOI: 10.1002/wcms.36.
- [11] Weininger, D. SMILES, a Chemical Language and Information System. 1. Introduction to Methodology and Encoding Rules / D. Weininger // Journal of Chemical Information and Computer Sciences. – 1988. – Vol. 28, no. 1. – P. 31–36. – DOI: 10.1021/ci00057a005.
- [12] Weininger, D. SMILES. 2. Algorithm for Generation of Unique SMILES Notation / D. Weininger, A. Weininger, J. L. Weininger // Journal of Chemical Information and Computer Sciences. – 1989. – Vol. 29, no. 2. – P. 97–101. – DOI: 10.1021/ci00062a008.
- [13] Dalby, A. Description of Several Chemical Structure File Formats Used by Computer Programs Developed at Molecular Design Limited / A. Dalby, J. G. Nourse, W. D. Hounshell [et al.] // Journal of Chemical Information and Computer Sciences. – 1992. – Vol. 32, no. 3. – P. 244–255. – DOI: 10.1021/ci00007a012.
- [14] Heller, S. R. InChI, the IUPAC International Chemical Identifier / S. R. Heller, A. McNaught, I. Pletnev [et al.] // Journal of Cheminformatics. – 2015. – Vol. 7. – Art. 23. – DOI: 10.1186/s13321-015-0068-4.
- [15] O’Boyle, N. M. Towards a Universal SMILES Representation – A Standard Method to Generate Canonical SMILES Based on the InChI / N. M. O’Boyle // Journal of Cheminformatics. – 2012. – Vol. 4. – Art. 22. – DOI: 10.1186/1758-2946-4-22.

References

- [1] Kuchuganov, A. V. Methodology of semantic analysis and search for graphic information: abstract of the dissertation for the degree of Doctor of Technical Sciences: specialty 05.13.01 “System analysis, management and information processing (in industry)” / A. V. Kuchuganov. – Izhevsk, 2018. – Text: direct.
- [2] Davletov, A. R. Modern methods of machine learning and OCR technology for automating document processing / A. R. Davletov. – Text: electronic // Bulletin of Science. – 2023. – No. 10 (67). – URL: <https://cyberleninka.ru/article/n/sovremennye-metody-mashinnogo-obucheniya-i-tehnologiya-ocr-dlya-avtomatizatsii-obrabotki-dokumentov> (date of access: 05/22/2026).
- [3] Rakov, N. S. Machine vision / N. S. Rakov, S. V. Palmov. – Text: electronic // Forum of young scientists. – 2018. – No. 4 (20). – URL: <https://cyberleninka.ru/article/n/mashinnoe-zrenie> (date of access: 05/22/2026).
- [4] Rublevsky, R. Landscape of basic terms in the field of generative AI, their relationship and use / R. Rublevsky. – Text: electronic // Habr. – 2025. – September 25 – URL: <https://habr.com/ru/articles/950600/> (access date: 05/22/2026).
- [5] Akhil, S. Overview of Tesseract OCR engine / S. Akhil. – Text: electronic // ResearchGate. – 2016. – Dec. – URL: <https://www.researchgate.net/publication/315834331> (access date: 05/22/2026).
- [6] Shen, Z. LayoutParser: A Unified Toolkit for Deep Learning Based Document Image Analysis / Z. Shen [et al.]. – Text: electronic // arXiv.org. – 2021. – arXiv:2103.15348. – URL: <https://arxiv.org/abs/2103.15348> (access date: 05/22/2026).
- [7] Xu, Y. LayoutLM: Pre-training of Text and Layout for Document Image Understanding / Y. Xu, M. Li, L. Cui [et al.]. – Text: electronic // arXiv.org. – 2019. – arXiv:1912.13318. – URL: <https://arxiv.org/abs/1912.13318> (access date: 05/22/2026).
- [8] Smith, R. An Overview of the Tesseract OCR Engine / R. Smith // Ninth International Conference on Document Analysis and Recognition (ICDAR 2007). – Washington: IEEE Computer Society, 2007. – Vol. 2. – P. 629–633. – DOI: 10.1109/ICDAR.2007.4376991. – URL: <https://doi.org/10.1109/ICDAR.2007.4376991> (access date: 05.22.2026).
- [9] Trinajstić, N. Chemical Graph Theory / N. Trinajstić. – 2nd ed. – Boca Raton : CRC Press, 1992. – 364 p.