

## ОЦИФРОВКА ХИМИЧЕСКИХ КНИГ С ИСПОЛЬЗОВАНИЕМ МАШИННОГО ЗРЕНИЯ

Алакшин М. С.<sup>1</sup>, Рыбак А. В.<sup>1</sup>, Такачёв Д. А.<sup>1</sup>, Трофимов И. Л.<sup>2,3</sup>

<sup>1</sup> Федеральное государственное бюджетное образовательное учреждение высшего образования «Иркутский государственный университет»

<sup>2</sup> Федеральный исследовательский центр «Иркутский институт химии им. А. Е. Фаворского Сибирского отделения Российской академии наук», г. Иркутск

<sup>3</sup> Государственная публичная научно-техническая библиотека Сибирского отделения Российской академии наук, г. Новосибирск

### Резюме

В статье рассматривается трансформация роли современных библиотек в условиях цифровой неопределенности и стремительного развития технологий искусственного интеллекта. ...

### Ключевые слова

искусственный интеллект, цифровая неопределенность, информационный шум, генеративные нейронные сети, интеллектуальная поисковая система, Retrieval Augmented Generation, семантический поиск, верификация, научное наследие, большие языковые модели

### Введение

Знания, содержащиеся в химических книгах, монографиях и архивных выпусках журналов, сохраняют высокую научную и практическую ценность: в них зафиксированы методики синтеза, экспериментальные наблюдения, справочные сведения о веществах и их свойствах, а также контекст, необходимый для воспроизводимости результатов. При этом существенная часть такого корпуса литературы до сих пор существует в виде физических изданий или в виде скан-копий, которые удобны для чтения человеком, но плохо приспособлены для автоматизированного анализа и интеграции в современные информационные системы.

На фоне развития информационных технологий и интеллектуального поиска становится актуальной задача извлечения знаний из химических книг с последующей структуризацией и верификацией. Однако на практике оцифровка часто сводится к распознаванию текста (OCR) и формированию «поискового PDF» [2], что позволяет выполнять лишь поверхностный текстовый поиск. В химической литературе значимая часть информации представлена не в виде текста, а в виде графических объектов: структурных формул, схем реакций. Если эти элементы не переводятся в машинно-обрабатываемые представления, то большая доля смысла документа остается вне цифрового контура и фактически недоступна для алгоритмов поиска, сопоставления и анализа [1].


В данной работе рассматривается подход к ком-

плексной оцифровке химической литературы, ориентированный не только на извлечение текстового слоя, но и на распознавание и структурирование графической химической информации, что позволяет разработать систему интеллектуального поиска по книгам.

### Машинное зрение и проблемы с извлечением данных из сканированных книг

Машинное зрение (Computer Vision, CV) представляет собой область искусственного интеллекта, изучающую методы автоматического анализа изображений и видео с целью извлечения из них семантически значимой информации [3]. В работе [4] машинное зрение выделяется как внешнее кольцо в общей классификации искусственного интеллекта (см. рис. 1).

Практическая необходимость применения методов компьютерного зрения в рамках данной работы обусловлена тем, что автоматизация обработки документов требует не только распознавания текста, но и предварительного анализа изображения документа. Как показано в работе А. Р. Давлетова, современные OCR-системы решают задачи предварительной обработки изображения, обнаружения текстовых областей, анализа компоновки страницы и последующего распознавания символов и слов [2]. Такой подход позволяет преобразовывать сканированные документы, PDF-файлы и изображения, полученные при сканировании, в машиночитаемый текст, пригодный для поиска, редактирования и дальнейшего извлечения данных [2].



**Рис. 1. Классификация искусственного интеллекта**

По сравнению с ручной обработкой автоматизированный подход сокращает время ввода данных, снижает влияние человеческого фактора, уменьшает количество ошибок и упрощает поиск и доступ к информации [2]. Кроме того, в рассматриваемой статье отмечается, что применение методов машинного обучения совместно с OCR позволяет не только конвертировать изображение в текст, но и извлекать из него полезные данные, а в практических сценариях такие решения демонстрируют высокую точность и значительный уровень автоматизации документооборота [2].

Для распознавания документов критично учитывать регулярную структуру страницы, взаимное расположение блоков и качество исходного скана, поскольку даже небольшие дефекты заметно ухудшают последующие этапы распознавания.

Большинство архивных химических книг и сканированных материалов характеризуются неоднородным качеством. В работе [5] выделялись следующие проблемы качества сканированных книг:

- Низкое разрешение / размытость
- Шум, зернистость, артефакты сжатия
- Неравномерная засветка / тени
- Ориентация страницы с малым поворотом

Эти факторы напрямую влияют на точность распознавания как и графических формул и реакций так и текста. Поэтому перед обработкой самой OCR необходимо сделать пред обработку и нормализацию изображения.

Поэтому задача комплексной оцифровки требует:

1. сегментации страницы на логические блоки
2. предварительной визуальной нормализации изображения
3. специализированных методов извлечения
4. сама обработка

## Список литературы

- [1] Кучуганов, А. В. Методология семантического анализа и поиска графической информации : автореферат диссертации на соискание ученой степени доктора технических наук : специальность 05.13.01 «Системный анализ, управление и обработка информации (в промышленности)» / А. В. Кучуганов. – Ижевск, 2018. – Текст : непосредственный.
- [2] Давлетов, А. Р. Современные методы машинного обучения и технология OCR для автоматизации обработки документов / А. Р. Давлетов. – Текст : электронный // Вестник науки. – 2023. – № 10 (67). – URL: <https://cyberleninka.ru/article/n/sovremennyye-metody-mashinnogo-obucheniya-i-tehnologiya-ocr-dlya-avtomatizatsii-obrabotki-dokumentov> (дата обращения: 22.05.2026).
- [3] Раков, Н. С. Машинное зрение / Н. С. Раков, С. В. Пальмов. – Текст : электронный // Форум молодых ученых. – 2018. – № 4 (20). – URL: <https://cyberleninka.ru/article/n/mashinnoe-zrenie> (дата обращения: 22.05.2026).
- [4] Рублевский, Р. Ландшафт основных терминов в области генеративного AI, их взаимосвязь и употребление / Р. Рублевский. – Текст : электронный // Хабр. – 2025. – 25 сент. – URL: <https://habr.com/ru/articles/950600/> (дата обращения: 22.05.2026).
- [5] Akhil, S. Overview of Tesseract OCR engine / S. Akhil. – Текст : электронный // ResearchGate. – 2016. – Dec. – URL: <https://www.researchgate.net/publication/315834331> (дата обращения: 22.05.2026).