

УДК 004.9

ОЦИФРОВКА ХИМИЧЕСКИХ КНИГ С ИСПОЛЬЗОВАНИЕМ МАШИННОГО ЗРЕНИЯ

Алакшин М. С.^{1,2}, Рыбак А. В.^{1,2}, Ткачёв Д. А.^{1,2}, Трофимов И. Л.^{2,3}

¹ Федеральное государственное бюджетное образовательное учреждение высшего образования «Иркутский государственный университет»

² Федеральный исследовательский центр «Иркутский институт химии им. А. Е. Фаворского Сибирского отделения Российской академии наук», г. Иркутск

³ Государственная публичная научно-техническая библиотека Сибирского отделения Российской академии наук, г. Новосибирск

Резюме

НАПИСАТЬ резюме

Ключевые слова

НАПИСАТЬ ключевые слова

DIGITIZATION OF CHEMISTRY BOOKS USING MACHINE VISION

Alakshin M. S.^{1,2}, Rybak A. V.^{1,2}, Tkachev D. A.^{1,2}, Trofimov I. L.^{2,3}

¹ Federal State Budgetary Educational Institution of Higher Education "Irkutsk State University"

² Federal Research Center "Irkutsk Institute of Chemistry named after A. E. Favorsky, Siberian Branch of the Russian Academy of Sciences Irkutsk

³ State Public Scientific and Technical Library of the Siberian Branch of the Russian Academy of Sciences, Novosibirsk

Abstract

НАПИСАТЬ резюме

Keywords

НАПИСАТЬ ключевые слова

Введение

Знания, содержащиеся в химических книгах, монографиях и архивных выпусках журналов, сохраняют высокую научную и практическую ценность: в них зафиксированы методики синтеза, экспериментальные наблюдения, справочные сведения о веществах и их свойствах, а также контекст, необходимый для воспроизводимости результатов. При этом существенная часть такого корпуса литературы до сих пор существует в виде физических изданий или в виде сканированных книг, которые удобны для чтения человеком, но плохо приспособлены для автоматизированного анализа и интеграции в современные информационные системы.

На фоне развития информационных технологий и интеллектуального поиска становится актуальной задача извлечения знаний из химических книг с последующей структуризацией и верификацией. Однако на практике оцифровка часто сводится к распознаванию текста и формированию «поискового PDF» [2], что позволяет выполнять лишь поверх-

ностный текстовый поиск. В химической литературе значимая часть информации представлена не в виде текста, а в виде графических объектов: структурных формул, схем реакций. Если эти элементы не переводятся в машинно-обрабатываемые представления, то большая доля смысла документа остается вне цифрового контура и фактически недоступна для алгоритмов поиска, сопоставления и анализа [1].

В данной работе рассматривается подход к комплексной оцифровке химической литературы, ориентированный не только на извлечение текстового слоя, но и на распознавание и структурирование графической химической информации, что позволяет разработать систему интеллектуального поиска по книгам.

Проблемы с извлечением данных из сканированных книг

Необходимость применения методов компьютерного зрения в рамках данной работы обусловлена тем, что автоматизация обработки документов требует не только распознавания текста, но и пред-

варительного анализа изображения документа. Как показано в работе А. Р. Давлетова [2], современные системы решают задачи предварительной обработки изображения, обнаружения текстовых областей, анализа компоновки страницы и последующего распознавания символов и слов. Такой подход позволяет преобразовывать сканированные документы, PDF-файлы и изображения, полученные при сканировании, в машинно-обрабатываемый текст, пригодный для поиска, редактирования и дальнейшего извлечения данных [2].

По сравнению с ручной обработкой автоматизированный подход сокращает время ввода данных, снижает влияние человеческого фактора, уменьшает количество ошибок и упрощает поиск и доступ к информации [2].

Классификация машинного зрения

Машинное зрение (Computer Vision, CV) представляет собой область искусственного интеллекта, изучающую методы автоматического анализа изображений и видео с целью извлечения из них семантически значимой информации [3]. В работе Рублевского [4] машинное зрение выделяется как внешнее кольцо в общей классификации искусственного интеллекта (см. рис. 1 а). Машинное зрение включающий задачи обработки документов, выделения структурных областей страницы и распознавания содержащейся на ней информации. Частным направлением компьютерного зрения является анализ изображений документов (Document Image Analysis или Document Understanding) (см. рис. 1 б), в рамках которого решаются задачи сегментации страницы, распознавания текста, таблиц, графики и иных содержательных элементов [6, 7].

Одной из наиболее известных задач данного направления является OCR (optical character recognition, оптическое распознавание символов), ориентированная на извлечение текстовой информации из изображений документов [8]. Однако, как было сказано, в химической литературе значимая часть информации представлена не только текстом, но и графическими структурами, поэтому наряду с OCR требуется использовать специализированные методы OCSR (optical chemical structure recognition, оптическое распознавание химической структур) [16], предназначенные для восстановления химических структур по их изображению. С методологической точки зрения OCSR не сводится к обычному OCR, поскольку предполагает восстановление молекулярного графа, а не только линейной последовательности символов. Таким образом, OCR и OCSR целесообразно рас-

сматривать как родственные, но не вложенные подзадачи анализа изображений химических документов (см. рис. 1 б).

Неоднородность изображений и их предобработка для улучшения качества работы системы

Большинство архивных химических книг и сканированных материалов характеризуются неоднородным качеством. В работе Akhil [5] выделялись следующие проблемы с изображениями при обработке:

- Низкое разрешение / размытость (рис. 2 а)
- Шум, зернистость, артефакты сжатия (рис. 2 б)
- Неравномерная засветлённость / тени (рис. 2 с)
- Ориентация страницы с малым поворотом (рис. 2 д)

Эти факторы напрямую влияют на точность распознавания как и графических формул и реакций так и текста. Поэтому перед распознаванием как текста, так и химических элементов для улучшения качества необходимо делать предобработку устраняющую названные проблемы с изображением.

Проблемы преобразования и стандарты представления химических реакций и молекул в машинно-обрабатываемом виде

Химические формулы и схемы реакций существенно сложнее для автоматической обработки, чем обычный текст, поскольку их естественное представление является не линейной последовательностью символов, а графовой структурой. В молекулярном графе вершины соответствуют атомам, а рёбра — химическим связям; реакция, в свою очередь, может рассматриваться как преобразование одного множества молекулярных графов в другое. Поэтому химическая запись несёт смысл не только через набор символов, но и через топологию, тип связей, ароматичность, заряды, стереохимию и пространственные отношения между фрагментами структуры. Именно это отличает задачу распознавания формул от классического OCR: если для текста ключевой является последовательность символов, то для химической формулы необходимо восстановить структуру графа и затем представить её в форме, пригодной для хранения, поиска и последующего анализа [9, 10].

В органической химии широко используются две распространённые графические нотации представления молекул: подробная (structural formula) и скелетная (line-angle notation) [25] (см. рис. 3). В подробной записи явно показываются атомы и зна-




Рис. 1. а) Классификация искусственного интеллекта; б) Классификация компьютерного зрения.
Fig. 1. a) Classification of artificial intelligence; b) Classification of computer vision.




Рис. 2. Пример плохого качества сканированных книг а) Размытость; б) Шум; в) Неравномерная засветлённость; д) Ориентация страницы с малым поворотом.

Fig. 2. An example of poor quality scanned books a) Blur; b) Noise; c) Uneven illumination; d) Page orientation with low rotation.




Рис. 3. Пример разных нотаций а) подробная; б) скелетная.
Fig. 3. Example of different notations a) detailed; b) skeletal.

чительная часть связей, что облегчает интерпретацию человеком, но увеличивает визуальную насыщенность изображения. В скелетной нотации, напротив, большинство атомов углерода и связанные с ними атомы водорода опускаются, а углеродный каркас кодируется линиями, вершины и концы которых интерпретируются как атомы углерода; гетероатомы, кратные связи, заряды и функциональные группы отображаются явно. Именно скелетная запись наиболее типична для органической химии и научных публикаций, однако она значительно усложняет автоматическое распознавание, так как часть информации в ней задаётся по соглашению, а не прописывается явно. В результате алгоритм должен не просто увидеть линии, но восстановить скрытые атомы, валентности и химически допустимую структуру [10].

В подробной записи явно показываются атомы и связи между ними, что облегчает интерпретацию человеком, но увеличивает визуальную насыщенность изображения. В скелетной нотации большинство атомов углерода и связанные с ними атомы водорода опускаются, а углеродный каркас кодируется линиями, вершины и концы которых интерпретируются как атомы углерода; гетероатомы, кратные связи, заряды и функциональные группы отображаются явно.

После распознавания графическое изображение молекулы должно быть переведено в машинно-обрабатываемый формат. В современной хемоинформатике для этого используются несколько основных способов представления структур. К числу наиболее распространённых относятся SMILES (Simplified Molecular Input Line Entry System), InChI (International Chemical Identifier), файловые форматы Molfile и SDF, XML-ориентированный CML (Chemical Markup Language), а для реакций — RXNfile, RDF, а также строковые языки наподобие SMIRKS для опи-

сания реакционных преобразований. Эти форматы различаются по назначению: одни удобны для компактной линейной записи и поиска, другие — для хранения полной структурной информации, координат, метаданных и реакционных схем. Обзор таких представлений и их роли в химической информатике приведён в работах по компьютерному представлению химических структур и форматам химических данных [10, 13, 14].

В данной работе в качестве основного текстового представления структуры выбран формат SMILES, предложенный как компактный язык линейной записи молекул [11, 12]. Его выбор обусловлен несколькими причинами. Во-первых, SMILES является кратким и человекочитаемым: одна молекула кодируется строкой, удобной для хранения в базах данных, индексации, поиска и передачи между программными компонентами. Во-вторых, SMILES широко поддерживается в современных библиотеках и инструментах хемоинформатики, что облегчает интеграцию распознанных структур в конвейер обработки, верификации и поиска. В-третьих, SMILES особенно удобен в задачах, где химическая информация должна быть включена в текстовый или гибридный контур обработки — например, при индексировании документов, построении RAG-систем, текстовом сравнении структур или использовании языковых моделей. В отличие от графического изображения, строка SMILES может быть быстро сопоставлена, нормализована, проверена на корректность и преобразована обратно в молекулярный граф, что делает её практически компромиссом между компактностью, выразительностью и вычислительной удобностью [10, 11].

При этом важным свойством SMILES является неоднозначность представления (см. рис. 4): одна и




Рис. 4. пример неоднозначного представление форму

Fig. 4. example of ambiguous form representation

та же молекула может быть записана несколькими различными, но эквивалентными строками. Это связано с тем, что линейная запись строится на основе обхода графа, а один и тот же граф допускает разные порядки обхода, разные точки старта, разные способы нумерации циклов, а также различные варианты явного или неявного задания некоторых структурных особенностей. Например, одна и та же структура может быть записана через разные эквивалентные последовательности ветвлений. В задачах хранения и поиска это создаёт проблему: если использовать произвольный SMILES, то идентичные молекулы могут быть представлены разными строками, что затрудняет дедупликацию, построение индексов и сопоставление результатов распознавания [12].

Для устранения этой неоднозначности используется канонический SMILES, то есть строковое представление, которое строится по детерминированному алгоритму канонизации и назначает данной структуре единственную «стандартную» форму записи в рамках конкретной программной системы. Идея канонизации состоит в том, чтобы сначала определить уникальный порядок атомов на основе свойств графа, а затем сгенерировать строку по фиксированным правилам обхода. Это позволяет переводить множество эквивалентных SMILES-представлений одной и той же молекулы к одной нормализованной форме. Однако важно учитывать, что канонический SMILES не является абсолютно универсальным мировым стандартом: разные программные пакеты могут использовать разные алгоритмы канонизации, поэтому канонические строки, полученные, например, в двух раз-

личных хемоинформатических библиотеках, могут отличаться при сохранении химической эквивалентности. Тем не менее в рамках одного конвейера обработки канонический SMILES является чрезвычайно полезным инструментом, поскольку обеспечивает нормализацию результатов распознавания, устойчивое сравнение структур и корректную интеграцию извлечённых данных в базы знаний и поисковые индексы [12, 14, 15]. Таким образом, выбор SMILES в сочетании с последующей канонизацией представляет собой практически оправданное решение для задач оцифровки и структурирования химической литературы.

Необходимость сегментации страницы и подходы к ней

Для распознавания документов критично учитывать регулярную структуру страницы и взаимное расположение блоков, поскольку страница научного документа представляет собой не просто непрерывное изображение текста, а композицию из различных смысловых областей: заголовков, основного текста, подписей к рисункам, таблиц, формул, схем, иллюстраций и служебных элементов [7].

Если этап сегментации пропускается или выполняется неточно, то система может воспринимать графические объекты как текст, объединять соседние колонки, терять подписи к рисункам, ошибочно включать части формул в текстовый поток или, наоборот, игнорировать важные текстовые фрагменты. Для химической литературы данная проблема особенно существенна, поскольку на одной странице часто од-




Рис. 5. Схема сегментации

Fig. 5. Segmentation scheme

новременно присутствуют обычный текст, структурные химические формулы, схемы реакций, таблицы и обозначения, различающиеся как по визуальной форме, так и по способу дальнейшей обработки.

Задача сегментации страниц относится к направлению анализа изображений документов (см. рис. 1 b) и играет роль промежуточного звена и позволяет перейти от обработки документа как единого изображения к обработке набора специализированных областей. После выделения таких областей (см. рис. 5) к каждой из них может быть применен собственный алгоритм: к текстовым блокам — OCR, к структурным формулам — OCSR, к таблицам — алгоритмы восстановления табличной структуры, к рисункам и схемам — отдельные процедуры анализа изображений. Таким образом, сегментация формирует основу всего конвейера оцифровки: *страница целиком* → *выделение блоков* → *специализированное распознавание* → *структурированное представление знаний*.

Современные подходы к анализу макета документа опираются на методы глубокого обучения, позволяющие автоматически выделять типовые области страницы и учитывать их пространственный контекст. В работе P. Renton, P. Chatto [6] и соавторов представлен инструмент *LayoutParser*, ориентированный на унифицированный анализ структуры документов на основе моделей глубокого обучения, что подтверждает практическую значимость этапа предварительной сегментации для дальнейшего извлечения информации из сложных страниц. Использование подобных подходов особенно актуально для

оцифровки архивных и сканированных книг, где вариативность компоновки, качество печати и наличие графических элементов делают задачу прямого распознавания без предварительного структурного анализа существенно менее надежной.

Наряду с методами, основанными на глубоком обучении, в задачах сегментации документов широко применяются и эвристические подходы, не требующие предварительного обучения модели. Такие методы опираются на геометрические и статистические свойства страницы: анализ вертикальных и горизонтальных проекционных профилей, поиск связанных компонент, анализ пробельных областей, рекурсивное разбиение страницы, а также сглаживание последовательностей пикселей или компонент. К числу классических подходов относятся, в частности, алгоритмы семейства *X-Y Cut*, использующие рекурсивное деление страницы по крупным пробельным промежуткам, и *Run-Length Smoothing Algorithm (RLSA)*, применяемый для группировки близко расположенных текстовых элементов в логические блоки [26, 27]. Преимуществом эвристических методов является их интерпретируемость, относительно низкая вычислительная сложность и отсутствие необходимости в размеченных обучающих выборках. Вместе с тем их эффективность, как правило, существенно зависит от качества скана, устойчивости верстки и наличия регулярной структуры документа, поэтому в случае архивных химических книг с шумом, сложной компоновкой страницы и большим количеством графических объектов такие методы часто используются либо как предварительный этап, либо как часть гибридных

ного конвейера совместно с моделями машинного зрения.

ДОПИСАТЬ

Поэтому задача комплексной оцифровки требует:

1. сегментации страницы на логические блоки
2. предварительной визуальной нормализации изображения
3. специализированных методов извлечения
4. сама обработка

Программное обеспечение для обработки страниц химических книг

В рамках настоящей работы, опираясь на результаты анализа предметной области и выявленные ограничения существующих подходов, было разработано программное обеспечение для оцифровки страниц химических книг. Функциональная логика системы и основные этапы обработки данных представлены на UML-диаграмме активностей [17] (рис. 6).

Программный комплекс реализован на языке Python, что объясняется его практической востребованностью в задачах обработки изображений и разработки интеллектуальных систем анализа документов. При проектировании использовались паттерны объектно-ориентированного проектирования [23], позволившие структурировать приложение и упростить его дальнейшее расширение. Для обеспечения единообразия и читаемости исходного кода соблюдались рекомендации Python Enhancement Proposals, в частности стандарты оформления кода PEP 8 [24].

Обработка химии

На основе представления молекул в формате SMILES было разработано программное обеспечение на основе предобеденных моделей для распознавания химических структур по изображениям. Для решения данной задачи применяются методы OCSR. В качестве основы для извлечения SMILES из изображений химических формул были рассмотрены три модели, представляющие различные подходы к задаче OCSR:

1. **MolScribe**. MolScribe представляет собой структурно-ориентированный подход к распознаванию химических изображений. Ключевая идея модели заключается в том, что химическую структуру целесообразно рассматривать не как набор независимых символов или линий, а как

молекулярный граф, который затем может быть преобразован в строковое представление. В рамках данного подхода изображение сначала переводится в набор визуальных признаков, после чего на их основе восстанавливается структура молекулы [18]. Таким образом, модель определяет положение атомов, типы связей между ними, наличие ароматичности, зарядов и особенности стереохимии. Благодаря этому MolScribe можно отнести к моделям, ориентированным на восстановление химического графа, а не только на последовательное распознавание элементов изображения.

2. **DECIMER (Deep Learning for Chemical Image Recognition)**. DECIMER представляет собой модель OCSR, основанную на методах глубокого обучения и обученную на больших объемах синтетически сгенерированных данных [19]. Архитектурно данный подход ориентирован на преобразование изображения химической структуры в строковое представление молекулы. В основе модели лежит схема, в которой сначала из изображения извлекаются визуальные признаки, а затем они используются для генерации последовательности токенов, описывающих химическую структуру. В качестве текстового представления в DECIMER применяется SELFIES, что позволяет повысить устойчивость генерации по сравнению с непосредственным предсказанием SMILES [20]. Существенным достоинством DECIMER является высокая точность распознавания на больших наборах данных, однако по сравнению с графо-ориентированными подходами модель в меньшей степени отражает молекулу именно как графовую структуру, поскольку её основной выход формируется в виде последовательности символов [20].
3. **Qwen3-VL**. Qwen3-VL представляет собой мультимодальную vision-language модель, способную анализировать графическую информацию и формировать текстовое описание содержимого изображения. В контексте задачи OCSR такая модель может рассматриваться как универсальный инструмент визуально-текстового преобразования, потенциально пригодный для интерпретации изображений химических структур. В отличие от специализированных моделей, таких как MolScribe и DECIMER, Qwen3-VL не разрабатывалась исключительно для задач химического распознавания, однако её мультимодальная ар-




Рис. 6. UML-диаграмма активностей программы по обработке страниц книг по химии

Fig. 6. UML activity diagram of a program for processing pages of chemistry books

хитектура позволяет использовать её в качестве сравнительного или вспомогательного подхода при анализе химических изображений [21].

Для применения локальных моделей MolScribe и DECIMER в работе использовались их встроенные механизмы обработки изображений химических структур. В случае Qwen3-VL он был также развёрнут локально, но взаимодействие с моделью осуществлялось программно через API с использованием системного промпта и набора демонстрационных примеров. Такой подход соответствует парадигме few-shot in-context learning, при которой модель адаптируется к требуемому формату ответа на основе контекста запроса без дополнительного дообучения параметров модели.

Использование метода «few-shot in-context learning» в молекулярных задачах согласуется с ре-

зультатами работы C. Fifty, J. Leskovec и S. Thrun [22], где предложен алгоритм CAMP для few-shot предсказания молекулярных свойств. В данной статье показано, что модель может выполнять предсказание на основе контекста из пар «объект–метка» за один проход, без этапа тонкой настройки модели, и при малом числе примеров превосходит ряд классических мета-обучающих-подходов [22]. Хотя работа [22] посвящена не распознаванию химических структур по изображениям, а задаче предсказания молекулярных свойств, она подтверждает применимость самой идеи few-shot in-context learning в химических задачах при ограниченном числе демонстраций. Поэтому в настоящей работе данный принцип используется как методологическое основание для применения Qwen3-VL в задаче распознавания химических формул по изображениям: модели предоставляется системная инструкция и несколько примеров соответствия меж-

ду изображением структуры и требуемым текстовым представлением.

Обработка текста

В качестве базового средства распознавания текста в работе использовалась библиотека EasyOCR. Данное программное средство представляет собой готовую OCR-систему с открытым исходным кодом, ориентированную на распознавание текста на изображениях и сканах документов. Библиотека поддерживает большое число языков, включая русский, и может быть легко интегрирована в программный конвейер на языке Python. EasyOCR удобна тем, что объединяет два ключевых этапа OCR-обработки: обнаружение текстовых областей на изображении и последующее распознавание символов в найденных фрагментах. Это позволяет использовать ее как базовый модуль распознавания без необходимости самостоятельно реализовывать этап сегментации текста.

Вместе с тем качество работы EasyOCR существенно зависит от состояния входного изображения. При наличии плохого качества сканированной книги на входе число ошибок распознавания возрастает. По этой причине в работе библиотека рассматривалась не только как самостоятельное средство OCR, но и как основа для дальнейшего улучшения результатов с помощью адаптивной предобработки изображения и последующей нормализации распознанного текста.

Предобработка изображений

Для повышения качества последующего распознавания в разработанном программном обеспечении реализован этап адаптивной предобработки изображений страниц. Его назначение состоит в том, чтобы до запуска модулей распознавания уменьшить влияние типичных дефектов сканирования выделенным Akhil [5]. В отличие от фиксированной схемы фильтрации, в разработанном алгоритме параметры обработки не задаются вручную заранее, а вычисляются автоматически на основе характеристик конкретного входного изображения.

Работа алгоритма начинается с загрузки изображения страницы и его преобразования в градации серого. Далее для получения грубой бинарной маски используется пороговая обработка по методу Отсу с инверсией яркости описанный описанного в работе Старовойтова [28]. Полученное бинарное изображение применяется не как финальный результат, а как промежуточный этап для оценки характерного размера текстовых элементов. На этой стадии выделяются внешние контуры связанных компонент, для каждой из которых вычисляется ограничивающий прямоуголь-

ник. Из дальнейшего анализа исключаются слишком малые компоненты, соответствующие шуму, а также крупные объекты, которые, как правило, относятся к линиям, рамкам или фрагментам графики. После фильтрации по высоте и ширине для оставшихся компонент вычисляется медианная высота, интерпретируемая как оценка характерной высоты символа на странице.

Полученная оценка используется в качестве основного управляющего параметра всей последующей предобработки. Через оценку для размера одного символа изображения масштабируется до 40 пикселей — эмпирически выбранная целевая высота символа, обеспечивающая устойчивую работу современных OCR-движков также в программе реализовано предотвращение чрезмерного увеличения изображения и роста вычислительных затрат. Таким образом, страницы с мелким текстом автоматически масштабируются сильнее, а страницы, уже имеющие достаточное разрешение, обрабатываются без лишнего увеличения.

На основе той же оценки высоты одного символа адаптивно вычисляются параметры локальной бинаризации. Размер окна бинаризации выбирается пропорционально примерно четырём высотам символа, после чего корректируется до ближайшего нечётного значения и дополнительно ограничивается размерами изображения. Такой выбор обусловлен тем, что окно должно быть достаточно большим для оценки локального фона, но не настолько большим, чтобы сглаживать полезные детали символов и тонких графических элементов. Константа адаптивной бинаризации также вычисляется автоматически как доля от размера окна, что позволяет согласованно изменять чувствительность метода в зависимости от масштаба текста на странице.

Кроме бинаризации, алгоритм автоматически подбирает интенсивность ряда дополнительных операций предобработки. Уровень шумоподавления, усиления контраста и резкости зависит от рассчитанного коэффициента масштабирования: чем меньше исходный размер символов и чем сильнее требуется увеличение изображения, тем более выраженной становится последующая коррекция. Это позволяет избежать как недостаточной обработки слабоконтрастных изображений, так и переусиления качественных сканов. Интенсивность морфологических операций также задаётся пропорционально оценённой высоте символа. Одна группа параметров ориентирована на удаление мелких артефактов и разрывов, другая — на объединение близко расположенных фрагментов

символов, что особенно важно при работе с деградировавшими сканами.

В реализованной схеме по умолчанию активируется коррекция небольшого поворота страницы, поскольку даже малый наклон существенно ухудшает как сегментацию строк текста, так и последующее распознавание. Дополнительно рассчитывается величина внутреннего отступа изображения, пропорциональная высоте символа, что позволяет снизить риск потери граничных элементов при дальнейшей обработке. В показанном варианте алгоритма удаление теней и границ страницы отключено, однако архитектура модуля допускает их включение при необходимости для отдельных классов документов.

Предложенный алгоритм представляет собой эвристически адаптивную схему предобработки, в которой центральную роль играет оценка характерного масштаба текста. Такой подход обеспечивает автоматическую настройку параметров под конкретную страницу без необходимости ручного подбора коэффициентов для каждого изображения. Это особенно важно для архивных химических книг, где качество сканов существенно варьируется от страницы к странице. Полученные после предобработки изображения затем передаются специализированным модулям распознавания: текстовые области — в OCR-подсистему. Тем самым предобработка выступает базовым этапом, повышающим устойчивость всего конвейера оцифровки.

Постобработка текста

После распознавания текста средствами EasyOCR выполнялась дополнительная постобработка результата. Ее основная цель заключалась в уменьшении числа ошибок, возникающих на этапе OCR, и повышении читаемости итогового текста. В работе использовались два варианта постобработки: эвристическая нормализация и нормализация с применением языковой модели YandexGPT 5 Lite.

Эвристическая постобработка основана на наборе заранее заданных правил очистки и исправления текста. На этом этапе из результата OCR удалялись очевидные артефакты распознавания, нормализовались пробелы, устранялись лишние разрывы строк, приводились к единообразному виду знаки пунктуации и исправлялись типичные замены символов. К числу таких ошибок относятся подмена схожих по начертанию символов, появление лишних символов, пропуски разделителей между словами и другие характерные дефекты OCR.

Преимущество эвристического подхода заключается в его простоте, высокой скорости работы и

полной предсказуемости результата. Однако его эффективность ограничена набором заранее предусмотренных правил. Если ошибка распознавания зависит от контекста или требует понимания смысла фразы, эвристические методы часто оказываются недостаточно точными.

Второй вариант постобработки основан на применении языковой модели YandexGPT 5 Lite. В этом случае распознанный OCR текст передавался в модель вместе с инструкцией исправить ошибки распознавания, сохранив исходный смысл, структуру и стиль фрагмента. Такой подход позволяет учитывать контекст соседних слов и восстанавливать более естественные текстовые конструкции даже в тех случаях, когда исходный результат OCR содержит несколько искажений одновременно.

Преимуществом использования языковой модели является более гибкая коррекция сложных ошибок, которые трудно устранить набором жестких правил. Особенно заметен эффект в случаях, когда OCR ошибается на уровне целых слов, нарушает границы слов или искажает отдельные буквенные последовательности. В таких ситуациях контекстная нормализация оказывается более эффективной, чем простая посимвольная замена.

При этом использование языковой модели требует аккуратной постановки инструкции. Важно ограничивать модель задачами исправления OCR-ошибок и не допускать произвольного переформулирования текста. Иначе существует риск появления изменений, которых не было в исходном документе. По этой причине постобработка с помощью LLM рассматривалась в работе именно как этап нормализации распознанного текста, а не как средство его свободного редактирования.

Апробация программного обеспечения

Выбран набор изображений молекул из сканированный книг в центральной научной библиотеке Иркутского научного центра Сибирского отделения Российской академии наук было собранно 20 молекул 10 из которых в скелетной нотации, а 10 в подробная нотации. Также выбран набор из 10 текстов страниц с текстом.

Для количественной оценки качества распознавания текста использовалась метрика WER. Данная метрика предназначена для сравнения распознанного текста с эталонным вариантом и показывает, насколько результат OCR отличается от правильной текстовой расшифровки на уровне слов. WER удобна тем, что учитывает наиболее важные для практической задачи типы ошибок: замену одного слова

другим, пропуск слова и вставку лишнего слова. Благодаря этому метрика позволяет оценивать не только посимвольные искажения, но и итоговое качество текста как целостной последовательности слов, что особенно важно при анализе результатов OCR для текстовых документов.

Преимущество WER состоит в том, что она хорошо отражает пригодность распознанного текста для дальнейшего использования. Даже если отдельные символы распознаны не полностью корректно, итоговое значение метрики показывает, насколько сильно искажено содержание текста в целом. Поэтому WER является удобным инструментом для сравнительного анализа различных конфигураций OCR-конвейера. Следует отдельно отметить, что в классической интерпретации WER меньшие значения соответствуют лучшему качеству распознавания. Если в таблицах и графиках работы используется преобразованная оценка сходства, полученная на основе WER, это необходимо явно указать в тексте. В таком случае большие значения будут соответствовать лучшему результату. Такое пояснение важно добавить, чтобы избежать неоднозначности при интерпретации экспериментальных данных.

Для апробации распознавания текста был проведён эксперимент на десяти тестовых изображениях, содержащих только текст. Рассматривались шесть конфигураций обработки: базовый EasyOCR без дополнительных этапов (в таблице 1 обозначен за OCR), OCR с адаптивной предобработкой изображения (в таблице 1 обозначен за OCR+пре), OCR с нормализацией текста при помощи языковой модели (в таблице 1 обозначен за OCR+норм), OCR с эвристической нормализацией (в таблице 1 обозначен за OCR+нормЭ), а также две комбинированные схемы, включающие предобработку и последующую нормализацию текста (в таблице 1 обозначен за OCR+пред+нормЭ и OCR+пред+норм).

Анализ результатов показывает, что наилучшее среднее качество достигается при использовании комбинированной схемы *OCR+пре+норм*. Среднее значение для данной конфигурации составляет 0,7693, что заметно превосходит как базовый запуск OCR, так и остальные варианты обработки. Это позволяет сделать вывод о том, что наилучший эффект достигается при совместном применении адаптивной предобработки изображения и последующей контекстной нормализации распознанного текста языковой моде-

лью.

Конфигурация *OCR+норм* также показывает высокий результат. Ее среднее значение составля-

ет 0,6625, а стандартное отклонение является наименьшим среди всех рассмотренных вариантов. Это свидетельствует о том, что постобработка с помощью языковой модели не только повышает среднее качество распознавания, но и делает результат более стабильным на разных тестовых изображениях.

Использование одной лишь адаптивной предобработки в конфигурации *OCR+пре* дает только умеренное улучшение по сравнению с базовым OCR. Среднее значение увеличивается с 0,4141 до 0,4746, однако по отдельным тестам результат оказывается нестабильным. В частности, на некоторых изображениях предобработка заметно улучшает итог, а на других, напротив, приводит к ухудшению качества. Это указывает на то, что предобработка полезна не сама по себе, а прежде всего как вспомогательный этап перед последующей интеллектуальной нормализацией текста.

Эвристическая нормализация без предобработки в конфигурации *OCR+нормЭ* не показывает общего улучшения относительно базового OCR. Среднее значение даже немного ниже, чем у исходного варианта. Это говорит о том, что набор фиксированных правил способен исправлять лишь часть типичных OCR-ошибок и уступает контекстной коррекции, выполняемой языковой моделью.

Комбинация *OCR+пре+нормЭ* демонстрирует небольшой прирост по сравнению с отдельным использованием эвристик, однако по среднему результату все равно значительно уступает схеме с LLM-нормализацией. Следовательно, эвристическая постобработка может быть полезна как вспомогательный инструмент, но не обеспечивает такого же качества исправления ошибок, как контекстно-зависимая языковая модель.

Таким образом, проведенный эксперимент показывает, что наибольший вклад в улучшение качества распознавания вносит этап постобработки текста, особенно при использовании YandexGPT 5 Lite. Адаптивная предобработка изображения также является полезной, но ее максимальный эффект проявляется именно в составе комбинированного конвейера. По совокупности результатов наиболее эффективной следует признать конфигурацию *OCR+пре+норм*.

Список литературы

другим, пропуск слова и вставку лишнего слова. Благодаря этому метрика позволяет оценивать не только посимвольные искажения, но и итоговое качество текста как целостной последовательности слов, что особенно важно при анализе результатов OCR для

Тест	OCR	OCR+пред	OCR+норм	OCR+нормЭ	OCR+пред+нормЭ	OCR+пред+норм
1	0,1603	0,4737	0,5465	0,1603	0,4503	0,9394
2	0,1742	0,5023	0,4838	0,1559	0,4909	0,8909
3	0,2151	0,0154	0,3588	0,2000	0,0310	0,4113
4	0,8734	0,8518	0,9240	0,8734	0,8500	0,9500
5	0,6488	0,7610	0,8750	0,5780	0,7121	0,9212
6	0,7091	0,6139	0,9643	0,7529	0,6450	0,8060
7	0,2100	0,3986	0,3720	0,1995	0,4203	0,8711
8	0,3656	0,0000	0,7923	0,3771	0,0000	0,0538
9	0,7210	0,7812	0,8785	0,7494	0,8031	0,8976
10	0,0636	0,3476	0,4295	0,0266	0,3523	0,9516
Среднее	0,4141	0,4746	0,6625	0,4073	0,4755	0,7693
Ст. откл.	0,2936	0,2975	0,2460	0,3053	0,2935	0,2983

Таблица 1. Сравнение качества распознавания текста при различных конфигурациях OCR

- [1] Кучуганов, А. В. Методология семантического анализа и поиска графической информации : автореферат диссертации на соискание ученой степени доктора технических наук : специальность 05.13.01 «Системный анализ, управление и обработка информации (в промышленности)» / А. В. Кучуганов. – Ижевск, 2018. – Текст : непосредственный.
- [2] Давлетов, А. Р. Современные методы машинного обучения и технология OCR для автоматизации обработки документов / А. Р. Давлетов. – Текст : электронный // Вестник науки. – 2023. – № 10 (67). – URL: <https://cyberleninka.ru/article/n/sovremennye-metody-mashinnogo-obucheniya-i-tehnologiya-ocr-dlya-avtomatizatsii-obrabotki-dokumentov> (дата обращения: 22.05.2026).
- [3] Раков, Н. С. Машинное зрение / Н. С. Раков, С. В. Пальмов. – Текст : электронный // Форум молодых ученых. – 2018. – № 4 (20). – URL: <https://cyberleninka.ru/article/n/mashinnoe-zrenie> (дата обращения: 22.05.2026).
- [4] Рублевский, Р. Ландшафт основных терминов в области генеративного AI, их взаимосвязь и употребление / Р. Рублевский. – Текст : электронный // Хабр. – 2025. – 25 сент. – URL: <https://habr.com/ru/articles/950600/> (дата обращения: 22.05.2026).
- [5] Akhil, S. Overview of Tesseract OCR engine / S. Akhil. – Текст : электронный // ResearchGate. – 2016. – Dec. – URL: <https://www.researchgate.net/publication/315834331> (дата обращения: 22.05.2026).
- [6] Shen, Z. LayoutParser: A Unified Toolkit for Deep Learning Based Document Image Analysis / Z. Shen [et al.]. – Текст : электронный // arXiv.org. – 2021. – arXiv:2103.15348. – URL: <https://arxiv.org/abs/2103.15348> (дата обращения: 22.05.2026).
- [7] Xu, Y. LayoutLM: Pre-training of Text and Layout for Document Image Understanding / Y. Xu, M. Li, L. Cui [et al.]. – Текст : электронный // arXiv.org. – 2019. – arXiv:1912.13318. – URL: <https://arxiv.org/abs/1912.13318> (дата обращения: 22.05.2026).
- [8] Smith, R. An Overview of the Tesseract OCR Engine / R. Smith // Ninth International Conference on Document Analysis and Recognition (ICDAR 2007). – Washington : IEEE Computer Society, 2007. – Vol. 2. – P. 629–633. – DOI: 10.1109/ICDAR.2007.4376991. – URL: <https://doi.org/10.1109/ICDAR.2007.4376991> (дата обращения: 22.05.2026).
- [9] Trinajstić, N. Chemical Graph Theory / N. Trinajstić. – 2nd ed. – Boca Raton : CRC Press, 1992. – 364 p.
- [10] Warr, W. A. Representation of Chemical Structures / W. A. Warr // Wiley Interdisciplinary Reviews: Computational Molecular Science. – 2011. – Vol. 1, no. 4. – P. 557–579. – DOI: 10.1002/wcms.36.
- [11] Weininger, D. SMILES, a Chemical Language and Information System. 1. Introduction to Methodology and Encoding Rules / D. Weininger // Journal of Chemical Information and Computer Sciences. – 1988. – Vol. 28, no. 1. – P. 31–36. – DOI: 10.1021/ci00057a005.

- [12] Weininger, D. SMILES. 2. Algorithm for Generation of Unique SMILES Notation / D. Weininger, A. Weininger, J. L. Weininger // Journal of Chemical Information and Computer Sciences. – 1989. – Vol. 29, no. 2. – P. 97–101. – DOI: 10.1021/ci00062a008.
- [13] Dalby, A. Description of Several Chemical Structure File Formats Used by Computer Programs Developed at Molecular Design Limited / A. Dalby, J. G. Nourse, W. D. Hounshell [et al.] // Journal of Chemical Information and Computer Sciences. – 1992. – Vol. 32, no. 3. – P. 244–255. – DOI: 10.1021/ci00007a012.
- [14] Heller, S. R. InChI, the IUPAC International Chemical Identifier / S. R. Heller, A. McNaught, I. Pletnev [et al.] // Journal of Cheminformatics. – 2015. – Vol. 7. – Art. 23. – DOI: 10.1186/s13321-015-0068-4.
- [15] O’Boyle, N. M. Towards a Universal SMILES Representation – A Standard Method to Generate Canonical SMILES Based on the InChI / N. M. O’Boyle // Journal of Cheminformatics. – 2012. – Vol. 4. – Art. 22. – DOI: 10.1186/1758-2946-4-22.
- [16] Optical chemical structure recognition. – Текст : электронный // Wikipedia. – URL: https://en.wikipedia.org/wiki/Optical_chemical_structure_recognition (дата обращения: 22.05.2026).
- [17] OMG Unified Modeling Language (OMG UML), Version 2.5.1 / Object Management Group. – 2017. – URL: <https://www.omg.org/spec/UML/2.5.1/PDF> (дата обращения: 22.05.2026).
- [18] MolScribe: Robust Molecular Structure Recognition with Image-To-Graph Generation / Y. Qian, J. Guo, Z. Tu [et al.]. – Текст : электронный // arXiv.org. – 2022. – arXiv:2205.14311. – URL: <https://arxiv.org/pdf/2205.14311> (дата обращения: 22.05.2026).
- [19] Rajan, K. DECIMER 1.0: deep learning for chemical image recognition using transformers / K. Rajan [et al.]. – Текст : электронный // ResearchGate. – 2021. – Aug. – URL: https://www.researchgate.net/publication/353957394_DECIMER_1.0_deep_learning_for_chemical_image_recognition_using_transformers (дата обращения: 22.05.2026).
- [20] Rajan, K. DECIMER 1.0: deep learning for chemical image recognition using transformers / K. Rajan, A. Zielesny, C. Steinbeck. – Текст : электронный // Journal of Cheminformatics. – 2021. – Vol. 13. – DOI: 10.1186/s13321-021-00538-8. – URL: <https://doi.org/10.1186/s13321-021-00538-8> (дата обращения: 22.05.2026).
- [21] Qwen Team. Qwen3-VL Technical Report / Qwen Team. – Текст : электронный // arXiv.org. – 2025. – arXiv:2511.21631. – URL: <https://arxiv.org/abs/2511.21631> (дата обращения: 22.05.2026).
- [22] Fifty, C. In-Context Learning for Few-Shot Molecular Property Prediction / C. Fifty, J. Leskovec, S. Thrun. – Текст : электронный // arXiv.org. – 2023. – arXiv:2310.08863. – URL: <https://arxiv.org/abs/2310.08863> (дата обращения: 22.05.2026).
- [23] Gamma, E. Design Patterns: Elements of Reusable Object-Oriented Software / E. Gamma, R. Helm, R. Johnson, J. Vlissides. – Reading : Addison-Wesley, 1995. – 395 p. – ISBN 0-201-63361-2. – Текст : непосредственный.
- [24] van Rossum, G. PEP 8 – Style Guide for Python Code / G. van Rossum, B. Warsaw, A. Coghlan. – Текст : электронный // Python.org. – URL: <https://peps.python.org/pep-0008/> (дата обращения: 23.05.2026).
- [25] Chapter 1 - Organic Chemistry Review / Hydrocarbons. Section 1.4 Condensed Structural and Line-Angle Formulas. – Текст : электронный // Hostos Community College Library Guides. – URL: <https://guides.hostos.cuny.edu/che120> (дата обращения: 22.05.2026).
- [26] Wong, K. Y. Document Analysis System / K. Y. Wong, R. G. Casey, F. M. Wahl // IBM Journal of Research and Development. – 1982. – Vol. 26, no. 6. – P. 647–656. – DOI: 10.1147/rd.266.0647.
- [27] Ha, J. Recursive X-Y Cut Using Bounding Boxes of Connected Components / J. Ha, R. M. Haralick, I. T. Phillips // Proceedings of the Third International Conference on Document Analysis and Recognition. – 1995. – Vol. 2. – P. 952–955. – DOI: 10.1109/ICDAR.1995.602058.
- [28] Старовойтов, В. В. Получение и обработка изображений на ЭВМ : учебно-методическое пособие / В. В. Старовойтов, Ю. И. Голуб. – Минск : БНТУ, 2018. – 204 с. – ISBN 978-985-550-770-4. – Текст : непосредственный.

References

- [1] Kuchuganov, A. V. Methodology of semantic analysis and search for graphic information: abstract of the dissertation for the degree of Doctor of Technical Sciences: specialty 05.13.01 "System analysis, management and information processing (in industry)" / A. V. Kuchuganov. – Izhevsk, 2018. – Text: direct.
- [2] Davletov, A. R. Modern methods of machine learning and OCR technology for automating document processing / A. R. Davletov. – Text: electronic // Bulletin of Science. – 2023. – No. 10 (67). – URL: <https://cyberleninka.ru/article/n/sovremennye-metody-mashinnogo-obucheniya-i-tehnologiya-ocr-dlya-avtomatizatsii-obrabotki-dokumentov> (date of access: 05/22/2026).
- [3] Rakov, N. S. Machine vision / N. S. Rakov, S. V. Palmov. – Text: electronic // Forum of young scientists. – 2018. – No. 4 (20). – URL: <https://cyberleninka.ru/article/n/mashinnoe-zrenie> (date of access: 05/22/2026).
- [4] Rublevsky, R. Landscape of basic terms in the field of generative AI, their relationship and use / R. Rublevsky. – Text: electronic // Habr. – 2025. – September 25 – URL: <https://habr.com/ru/articles/950600/> (access date: 05/22/2026).
- [5] Akhil, S. Overview of Tesseract OCR engine / S. Akhil. – Text: electronic // ResearchGate. – 2016. – Dec. – URL: <https://www.researchgate.net/publication/315834331> (access date: 05/22/2026).
- [6] Shen, Z. LayoutParser: A Unified Toolkit for Deep Learning Based Document Image Analysis / Z. Shen [et al.]. – Text: electronic // arXiv.org. – 2021. – arXiv:2103.15348. – URL: <https://arxiv.org/abs/2103.15348> (access date: 05/22/2026).
- [7] Xu, Y. LayoutLM: Pre-training of Text and Layout for Document Image Understanding / Y. Xu, M. Li, L. Cui [et al.]. – Text: electronic // arXiv.org. – 2019. – arXiv:1912.13318. – URL: <https://arxiv.org/abs/1912.13318> (access date: 05/22/2026).
- [8] Smith, R. An Overview of the Tesseract OCR Engine / R. Smith // Ninth International Conference on Document Analysis and Recognition (ICDAR 2007). – Washington: IEEE Computer Society, 2007. – Vol. 2. – P. 629–633. – DOI: 10.1109/ICDAR.2007.4376991. – URL: <https://doi.org/10.1109/ICDAR.2007.4376991> (access date: 05.22.2026).
- [9] Trinajstić, N. Chemical Graph Theory / N. Trinajstić. – 2nd ed. – Boca Raton : CRC Press, 1992. – 364 p.
- [10] Warr, W. A. Representation of Chemical Structures / W. A. Warr // Wiley Interdisciplinary Reviews: Computational Molecular Science. – 2011. – Vol. 1, no. 4. – P. 557–579. – DOI: 10.1002/wcms.36.
- [11] Weininger, D. SMILES, a Chemical Language and Information System. 1. Introduction to Methodology and Encoding Rules / D. Weininger // Journal of Chemical Information and Computer Sciences. – 1988. – Vol. 28, no. 1. – P. 31–36. – DOI: 10.1021/ci00057a005.
- [12] Weininger, D. SMILES. 2. Algorithm for Generation of Unique SMILES Notation / D. Weininger, A. Weininger, J. L. Weininger // Journal of Chemical Information and Computer Sciences. – 1989. – Vol. 29, no. 2. – P. 97–101. – DOI: 10.1021/ci00062a008.
- [13] Dalby, A. Description of Several Chemical Structure File Formats Used by Computer Programs Developed at Molecular Design Limited / A. Dalby, J. G. Nourse, W. D. Hounshell [et al.] // Journal of Chemical Information and Computer Sciences. – 1992. – Vol. 32, no. 3. – P. 244–255. – DOI: 10.1021/ci00007a012.
- [14] Heller, S. R. InChI, the IUPAC International Chemical Identifier / S. R. Heller, A. McNaught, I. Pletnev [et al.] // Journal of Cheminformatics. – 2015. – Vol. 7. – Art. 23. – DOI: 10.1186/s13321-015-0068-4.
- [15] O'Boyle, N. M. Towards a Universal SMILES Representation – A Standard Method to Generate Canonical SMILES Based on the InChI / N. M. O'Boyle // Journal of Cheminformatics. – 2012. – Vol. 4. – Art. 22. – DOI: 10.1186/1758-2946-4-22.
- [16] Optical chemical structure recognition. – Text: online // Wikipedia. – URL: https://en.wikipedia.org/wiki/Optical_chemical_structure_recognition (date accessed: 22.05.2026).
- [17] OMG Unified Modeling Language (OMG UML), Version 2.5.1 / Object Management Group. – 2017. – URL: <https://www.omg.org/spec/UML/2.5.1/PDF> (date accessed: 22.05.2026).
- [18] MolScribe: Robust Molecular Structure Recognition with Image-To-Graph Generation / Y. Qian, J. Guo, Z. Tu [et al.]. – Text: online // arXiv.org. – 2022. – arXiv:2205.14311. – URL: <https://arxiv.org/pdf/2205.14311> (date accessed: 22.05.2026).